Expediente completo — descubrimiento de un clado de cisteína desulfurasas tipo SCLY en algas

Documento interno de trabajo. No es un manuscrito: es el expediente con todo lo que se hizo, por qué se eligió cada herramienta, qué dio cada paso, qué se descartó y por qué.

0. Cómo leer este documento

Está ordenado **por el orden en que pasaron las cosas**, no por el orden en que irían en un paper. Eso es deliberado: la parte más valiosa del proyecto es justamente que una hipótesis inicial equivocada se detectó, se corrigió y la corrección resultó ser el hallazgo.

Cada sección trae:

- **Qué se hizo** y con qué herramienta.
- **Por qué esa herramienta** y no otra.
- **Qué dio** — con los números exactos.
- **Qué no prueba** — la limitación, explícita.

Las secciones marcadas con ⚠ contienen material que **se descartó**. Están incluidas a propósito: un director o un revisor va a preguntar qué pasó con ellas.

Al final: lo que falta para blindar la publicación (§8) y las opciones de paper (§9).

1. Resumen ejecutivo

En el genoma de *Scenedesmus* sp. PABB004 se buscaba una segunda cisteína desulfurasa plastidial (NFS2). Lo que se encontró fue otra cosa, y mejor.

1. El cebo que se había usado para buscar NFS2 —`PNW80545.1` de *Chlamydomonas reinhardtii*, anotado como "NFS2" en AlgaePath— **no es NFS2**. Es el miembro de un tercer grupo de aminotransferasas clase V, distinto de NFS1 (ISC, mitocondrial) y de NFS2 (SUF, plastidial).
2. Ese tercer grupo es homólogo de la **selenocisteína liasa (SCLY)** animal. Se lo identifica por un rasgo de una sola posición: en el bucle catalítico, inmediatamente después de la cisteína del sitio activo hay una **histidina** (`SAGxACH`). NFS1 lleva ahí serina/treonina; NFS2 lleva serina.
3. *Scenedesmus* sp. PABB004 tiene **los tres genes**: NFS1 (`KAF8057853.1`), NFS2 (`KAF8071197.1`) y el SCLY-like, que estaba **mal anotado** — oculto dentro de un ORF quimérico de 3383 aa (`KAF8071094.1`).
4. El gen SCLY-like se **curó manualmente** y la curación se **validó con lecturas crudas de RNA-seq** de la propia cepa: la unión exón-exón del modelo corregido tiene 29 lecturas de soporte; la del modelo automático del anotador tiene **cero**.

5. Un barrido sobre **119 proteomas de referencia** (2.110.345 secuencias) recupera **66 proteínas SCLY-like en 56 especies de 7 linajes algales**, formando un clado monofilético con soporte 0,96 y con la SCLY humana como rama hermana.
6. El clado está **ausente** en las 6 embriofitas, las 12 rodofitas y 14 proteomas de estramenopilas no diatomeas examinados. La pérdida en plantas terrestres y en algas rojas es independiente.
7. La firma `G-x-x-C-H` es **invariante**: entropía de Shannon = 0,000 bits en las 66 secuencias.

El titular honesto: *primera descripción sistemática de un clado de cisteína desulfurasas tipo selenocisteína liasa en algas, con un caso de curación génica validado por RNA-seq.*

Lo que NO se puede decir: que es una familia nueva (no lo es: es el ortólogo algal de SCLY, antes no descrito como grupo), ni que se demostró actividad sobre selenocisteína (eso requiere ensayo enzimático).

2. Cronología

2.1 — Punto de partida: ¿hay una segunda NFS2 en PABB004?

Qué se hizo. BLASTp del cebo `PNW80545.1` (*C. reinhardtii*, etiquetado "NFS2" en AlgaePath) contra las proteínas de *Scenedesmus* sp. PABB004 (BioProject `PRJNA637367`, scaffold `JABVCE010000002.1`).

Por qué BLASTp. Para una primera pesca de homólogos cercanos dentro de un genoma chico es lo correcto: rápido, con estadística bien calibrada, y no necesita un modelo previo de la familia.

Qué dio. Un único hit fuerte, pero contra una proteína de **3383 aa** (`KAF8071094.1`) — absurdamente larga para una desulfurasa, que ronda los 450–500 aa. El alineamiento cubría sólo un tramo interno.

Cluster Composition (Click the ⊞ to see the cluster contents)	Cluster Ancestor	Cluster Representative Sequence (Representative may differ from filtered organism(s))	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
⊞1 member(s), 1 organism(s)	green algae	hypothetical protein HT031_001176 [Scenedesmus sp. PABB004]	622	622	100%	0.0	100.00%	3383	KAF8071094.1
⊞1 member(s), 1 organism(s)	green algae	pyridoxal phosphate-dependent transferase [Scenedesmus sp. NREL 46B-D3]	484	484	82%	1e-171	69.01%	480	KAF6265975.1
⊞1 member(s), 1 organism(s)	green algae	pyridoxal phosphate-dependent transferase [Scenedesmus bijugus var. obtusiu…	318	318	53%	1e-108	67.06%	299	KAN4133973.1
⊞1 member(s), 1 organism(s)	green algae	NFS1 [Scenedesmus sp. PABB004]	231	231	72%	4e-73	44.08%	487	KAF8057853.1
⊞1 member(s), 1 organism(s)	green algae	cysteine desulfurase [Scenedesmus sp. NREL 46B-D3]	222	222	72%	5e-70	41.59%	412	KAF6266189.1
⊞1 member(s), 1 organism(s)	green algae	cysteine desulfurase [Scenedesmus bijugus var. obtusiusculus]	128	247	72%	2e-33	43.24%	521	KAN4128266.1
⊞1 member(s), 1 organism(s)	green algae	NFS2 [Scenedesmus sp. PABB004]	88.5	88.5	48%	3e-19	35.09%	521	KAF8071197.1

Hits de BLASTp contra el genoma de Scenedesmus

Qué no prueba. Un hit de BLASTp contra un ORF largo no dice si el ORF es real, si es una fusión génica verdadera o si es un error de anotación. Esa pregunta quedó abierta durante casi todo el proyecto y recién se cerró en §2.13.

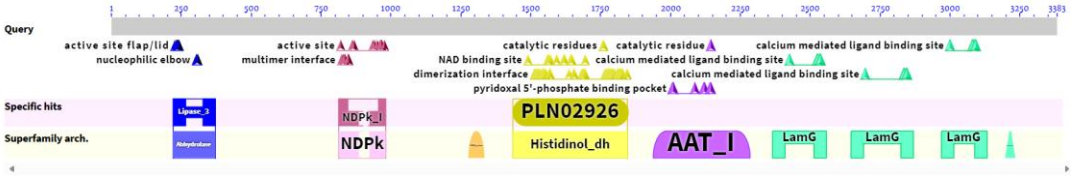
2.2 — Diseccionar el ORF de 3383 aa

Qué se hizo. CD-Search (NCBI Conserved Domain Database) sobre `KAF8071094.1` completo, y BLASTp del tramo recortado contra el propio ORF para localizar los límites.

Por qué CD-Search. Es el servidor que hace lo que se necesitaba: dado un ORF largo sin anotación confiable, devolver la **arquitectura de dominios** con coordenadas y E-value. Un BLAST te dice "se parece a X"; CD-Search te dice "tiene estos cinco bloques en estas posiciones".

Qué dio. Cinco bloques de dominios sin relación funcional entre sí, en un mismo marco de lectura:

Bloque	Dominio	Función esperada
1	Lipase_3 / Abhydrolase	lipasa
2	NDPk	nucleósido-difosfato quinasa
3	Histidinol_dh (PLN02926)	biosíntesis de histidina
4	**AAT_I** (aminotransferasa clase I/II/V)	**la desulfurasa**
5	tres repeticiones LamG	laminina G



Arquitectura de dominios del ORF de 3383 aa

hypothetical protein HT031_001176 [Scenedesmus sp. PABB004]

Sequence ID: KAF8071094.1 Length: 3383 Number of Matches: 1

Range 1: 1936 to 2288 GenPept Graphics ▼ Next Match ▲ Pr

Score	Expect	Method	Identities	Positives	Gaps
298 bits(762)	8e-89	Compositional matrix adjust.	218/398(55%)	264/398(66%)	45/398(11%)

```
Query  53    TGCIYLDYNATTPIFPEVANEMAPFVFEHFGNPSSGHVYGRACKSALDTARQRVAALIAA  112
            +GCIYLDYNATTPI+PEVA  M PF +E FGNPSSGH +GR  ++A+D AR+ VA LI A
Sbjct  1936  SGCIYLDYNATTPIYPEVAAAMRPFSYELFGNPSSGHAHGRRTRAAVDAARRAVAGLIGA  1995

Query  113   ASPSEVHFTSCGTESDNWAVYGAVMAARAAAAGAAGAAGYVPHVVASAVEHPAVLAHLTH  172
             SP EV FTS GTE+DNWA++GAVMA RAA A A       +PHVV SA+EHPAV A L
Sbjct  1996  PSPGEVVFTSGGTEADNWAIWGAVMARRAAVAPA------LPHVVTSAIEHPAVTACLAA  2049

Query  173   LQEQGLLSYTLVPVDGEGLVSPADVAAAVTPATCLVTVMHSNNEVGAVQPIAHIAAAARA  232
            L + GL ++  VPV  EGLVSPADV AA+TP+T LV++MHSNNE+GA+QP+A IAAA +A
Sbjct  2050  LADAGLCTHARVPVSSEGLVSPADVVAALTPSTVLVSIMHSNNEIGALQPVAAIAAAVKA  2109

Query  233   AHARLTAGGGGATSPSPSLSPSSSTGGSSSGTSGSSWRPRLLVHSDAAQSTGKVDLDVGA  292
                                                P +LVH+DAAQS GKV +DVG
Sbjct  2110  VA-----------------------------------PGVLVHTDAAQSVGKVRVDVGE  2133

Query  293   LDLDLMTLVGHKFGAPKGVAALYVRHGTALPNYFYGGGQEGGRRAGTENVMQVVGLGAAA  352
            L +DL+TL+GHKFGAPKGV ALYVR G  L N   GGGQEGGRR GTE+V+ + GLGAAA
Sbjct  2134  LGVDLLTLIGHKFGAPKGVGALYVRTGVPLANLLCGGGQEGGRRGGTESVLLLAGLGAAA  2193

Query  353   AITVRERRQLQTHMGDMAQRLLAAVRAQVAPAEQDKLRLNGPADPTRRLPNTLSLSIRGL  412
             +  RE      H   M  RL A + A         + +NGPADP  RLPNTLS+S+ GL
Sbjct  2194  ELAARELPAAAAHQRAMRDRLAAGLLAA---LPPALVCVNGPADPAARLPNTLSISVAGL  2250

Query  413   NSGAALAALSGRLAASAGAACHSSGAASVSAVLRAMKV  450
             + + L  LS RLAASAGAACHS+G  SVS VL+A+++
Sbjct  2251  AAASLLEQLSDRLAASAGAACHSTGGPSVSPVLQAVQL  2288
```

BLASTp del tramo recortado contra el ORF completo

Ningún organismo conocido fusiona lipasa + NDP quinasa + histidinol deshidrogenasa + aminotransferasa + laminina G en una sola cadena. **Diagnóstico: el ORF es un artefacto de anotación** — el predictor pegó varios genes vecinos en un transcripto único. El tramo de aminotransferasa se recortó a mano y se lo llamó provisoriamente **"HText"**.

Qué no prueba. El recorte manual fija límites arbitrarios. Las consecuencias de eso aparecen en §2.4 y se arreglan recién en §2.13.

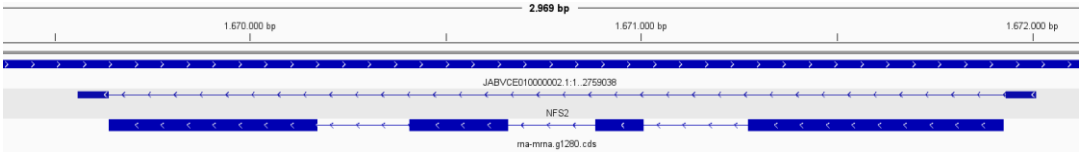
2.3 — La segunda búsqueda, y la NFS2 verdadera

Qué se hizo. Búsqueda más permisiva contra el proteoma de PABB004 con cebos de NFS1 y NFS2 de *Arabidopsis thaliana* (`O49543`, `Q93WX6`).

Qué dio. Dos proteínas limpias, de longitud normal:

Proteína	Accesión	aa	Identidad con el ortólogo de *A. thaliana*
NFS1 (mitocondrial, vía ISC)	`KAF8057853.1`	487	64,2 %
NFS2 (plastidial, vía SUF)	`KAF8071197.1`	521	58,1 %

Es decir: la NFS2 de PABB004 **ya estaba anotada y era correcta**. El locus `HT031_001280`, 1.669.642–1.671.931, cuatro exones.



Estructura del locus de NFS2 en el genoma de PABB004

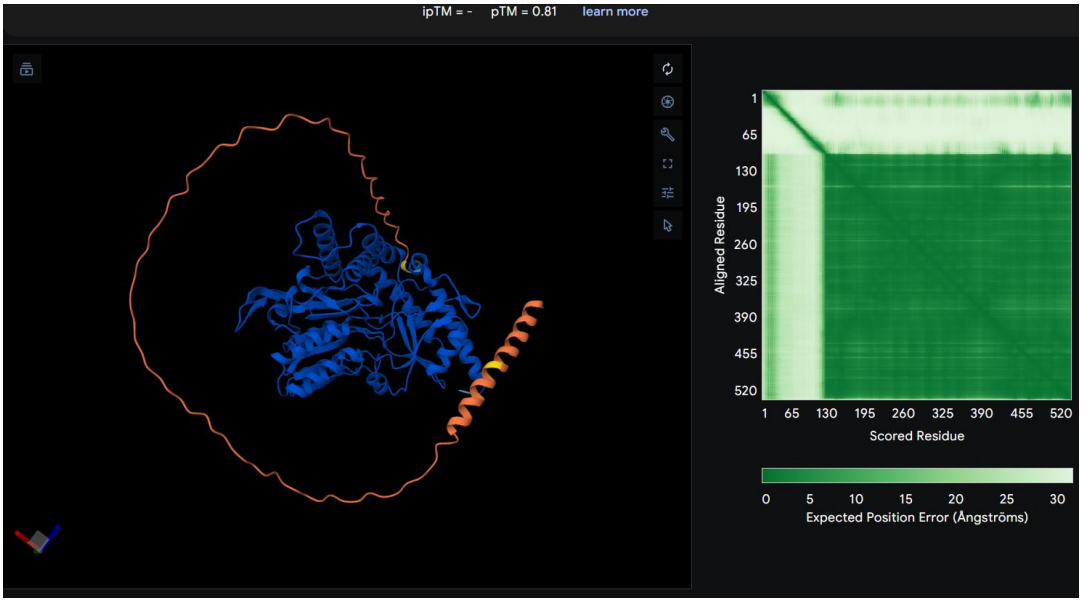
La pregunta cambió. Si `KAF8071197.1` es la NFS2, ¿qué es "HText"? Y si HText se parece tanto al cebo de Chlamydomonas, ¿qué es el cebo?

2.4 — Modelado estructural y localización: primeras señales contradictorias ⚠

Qué se hizo. Modelo de AlphaFold2 de HText recortado; DeepLoc 2.1 y LOCALIZER para predecir destino subcelular; superposición en PyMOL contra IscS de *E. coli*.

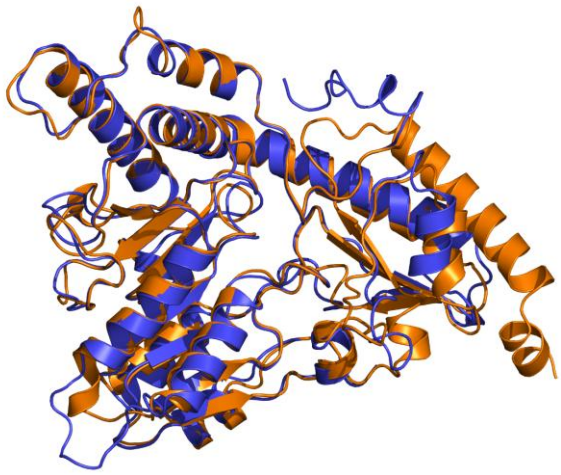
Qué dio.

El modelo de AlphaFold mostró el plegamiento de aminotransferasa clase V (tipo I de fold PLP) bien resuelto, pero con **~125 residuos N-terminales de confianza nula** colgando como un lazo desordenado — consecuencia directa del recorte manual del §2.2.



Modelo de AlphaFold de HText con el extremo N-terminal desordenado

La superposición contra IscS dio un núcleo catalítico prácticamente idéntico y dos extremos divergentes:



Superposición de HText (azul) contra IscS de E. coli (naranja)

Y DeepLoc dio **plástido con probabilidad 0,9477** para HText:

Predicted localizations: Plastid
Predicted membrane association: Soluble
Predicted signals: Chloroplast transit peptide

Localization	Cytoplasm	Nucleus	Extracellular	Cell membrane	Mitochondrion	Plastid	Endoplasmic reticulum	Lysosome/Vacuole	Golgi apparatus	Peroxisome
Probability	0.2205	0.0606	0.0548	0.0475	0.1045	0.9477	0.0179	0.0265	0.0382	0.0143

Membrane association	Peripheral	Transmembrane	Lipid anchor	Soluble
Probability	0.3920	0.1280	0.1310	0.8140

Predicción de localización de HText sobre el recorte original

```
# -----------------
# LOCALIZER 1.0.4 Predictions
# -----------------
Identifier Chloroplast          Mitochondria         Nucleus
NFS2-HText Y (0.71 | 1-70)      -                    -
NFS2-PABB  Y (0.907 | 1-29)     Y (0.989 | 1-22)     Y (PSAKRGR,RRRAVVRRRGGSSAAAAPRR)
```

Salida de LOCALIZER

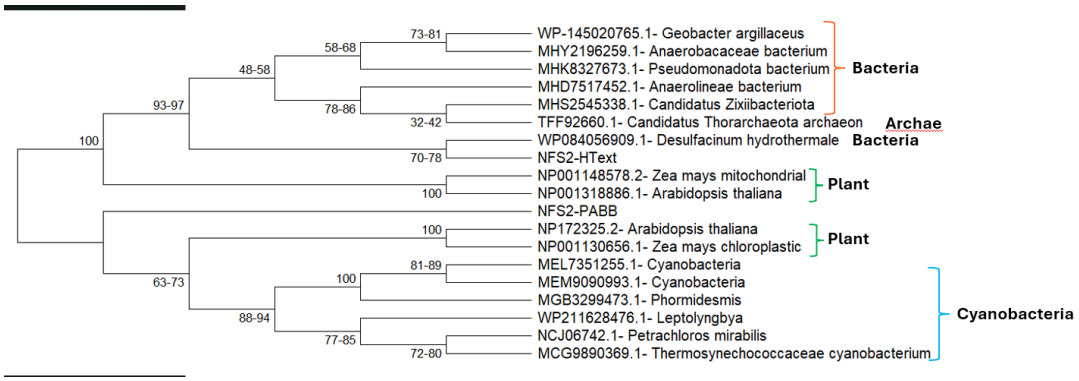
⚠ **Este resultado era un artefacto.** El recorte del §2.2 empezaba en una región de baja complejidad rica en Ser/Arg/Ala que **imita un péptido de tránsito al cloroplasto**. DeepLoc leyó eso como señal plastidial. Cuando en §2.10 se corrió el panel completo con controles de destino conocido, el clado SCLY-like dio mediana de plástido **0,13** y sólo 2 de 61 secuencias se predijeron plastidiales.

Lección metodológica que quedó como norma del proyecto. Un predictor de localización corrido sobre una secuencia de límites inciertos no es evidencia. Desde acá en adelante, toda corrida de predictor lleva **panel de control de destino conocido** obligatorio.

2.5 — El árbol que no cerraba: punto de inflexión ⚠

Qué se hizo. Árbol preliminar en MEGA con HText, NFS2-PABB, ortólogos vegetales, bacterias, cianobacterias y arqueas.

Qué dio.



Árbol preliminar en MEGA

HText **no caía con las NFS2 vegetales**. Caía al lado del grupo bacteriano/arqueano, con soporte bajo (70–78), mientras que NFS2-PABB caía exactamente donde debía, con las NFS2 plastidiales de *Arabidopsis* y *Zea*. Si HText fuera una segunda NFS2, tenía que agrupar con las NFS2. No lo hacía.

Por qué este árbol no alcanzaba para concluir. Pocos taxones, alineamiento sobre secuencias completas (incluyendo extensiones no homólogas), soportes bajos. Un árbol así levanta sospecha, no cierra un caso. Pero la sospecha fue la correcta.

Decisión tomada acá: rehacer el análisis de cero, con un muestreo sistemático y con un criterio de asignación que no dependa del árbol.

2.6 — La reasignación: el bucle catalítico

Qué se hizo. En lugar de confiar en BLAST, en el árbol o en el TM-score, se fue al **bucle catalítico** — los ~10 residuos que rodean la cisteína del sitio activo, que es donde las tres subfamilias de cisteína desulfurasas se diferencian funcionalmente.

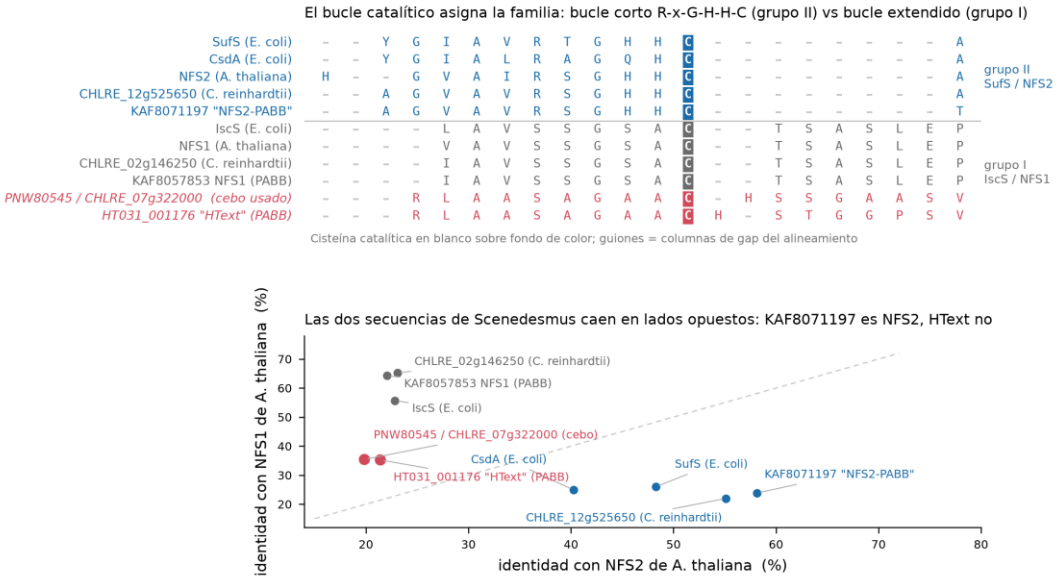
Por qué ese criterio y no BLAST / árbol / estructura.

- **BLAST** devuelve el pariente más parecido en la base, que puede estar mal anotado (fue exactamente lo que pasó: el cebo estaba mal etiquetado y el error se propagó).
- **TM-score global** no sirve: todas las aminotransferasas clase V comparten el mismo plegamiento y dan 0,65–0,95 entre sí. Es un criterio que no discrimina.
- **El árbol** depende del muestreo y del alineamiento.
- **El bucle catalítico** es un carácter discreto, leíble a ojo, con literatura bioquímica detrás: la longitud y composición del bucle determinan si la enzima entrega el azufre a un aceptor directo (grupo I, bucle largo y flexible) o a una proteína transportadora (grupo II, bucle corto).

Qué dio.

Grupo	Representantes	Bucle catalítico	Cys catalítica
I — ISC / NFS1 / IscS	IscS P0A6B7, NFS1 At O49543	S-S-G-S-A-C-T-S (extendido)	Cys328 en IscS
II — SUF / NFS2 / SufS	SufS P77444, NFS2 At Q93WX6	R-x-G-H-H-C (corto)	Cys364 en SufS
III — SCLY-like	SCLY humana Q96I15, HText, PNW80545.1	**`S-A-G-[A/S]-A-C-H-S`**	—

La marca del grupo III es la **histidina inmediatamente después de la cisteína**. Ni el grupo I ni el II la tienen.



Asignación de familia por el bucle catalítico

Consecuencias inmediatas:

- PNW80545.1 (= CHLRE_07g322000v5 = A0A2K3DJ46) **no es NFS2 de Chlamydomonas.** Es su SCLY-like. En UniProt figura apenas como "Aminotransferase class V domain-containing protein", sin familia InterPro asignada.
- La NFS2 verdadera de *Chlamydomonas* es A0A2K3D4F5 (CHLRE_12g525650v5, 470 aa); la NFS1 verdadera es A0A2K3E3W0 (= PNW87417.1, CHLRE_02g146250v5, 464 aa).
- HText es el SCLY-like de PABB004, con bucle LAASAGAACHSTGGPSVS.
- **PABB004 tiene los tres genes.**

Esto es la bisagra del proyecto. Todo lo anterior se reinterpretó a la luz de esto; todo lo posterior salió de acá.

2.7 — El barrido pan-algal

Qué se hizo. Se bajaron **119 proteomas de referencia** de UniProt (107 algales + 12 de contraste: 6 embriofitas, humano, *Drosophila*, levadura, *Dictyostelium*, *Tetrahymena*, *Plasmodium*) — **2.110.345 secuencias** en total. Búsqueda con **phmmer** usando 10 cebos de las tres subfamilias, Z fijado al tamaño del universo, corte E < 1 × 10^{-10}.

Por qué phmmer y no BLASTp. phmmer usa un modelo probabilístico de perfil construido sobre la query; es más sensible que BLASTp para homología remota, que es exactamente el régimen de este problema (identidades del 25–40 % entre subfamilias). Fijar Z al universo real evita que el E-value dependa del tamaño del proteoma individual, lo que haría incomparables las especies.

Por qué proteomas de referencia de UniProt y no todo NCBI. Un proteoma de referencia es un juego no redundante, uno por especie, con anotación estable. Si se tira contra nr, el conteo queda dominado por cuántas veces se secuenció cada especie, no por biología.

Qué dio. 617 proteínas de aminotransferasa clase V.

Luego: extracción del dominio **PF00266** con hmmsearch, alineamiento con **FAMSA**, filtrado de columnas con ocupación ≥ 0,35 (**386 de 768 columnas** sobrevivieron), árbol de máxima verosimilitud con **VeryFastTree** (modelo LG+Γ, 1000 réplicas de soporte), enraizado en el grupo II.

Por qué alinear sólo el dominio y no la proteína completa. Las tres subfamilias difieren en extensiones N y C terminales que no son homólogas entre sí (péptidos de tránsito, extensiones de longitud variable). Alinearlas completas mete ruido en columnas que no tienen señal filogenética. Recortar al dominio Pfam es la práctica estándar y acá era imprescindible.

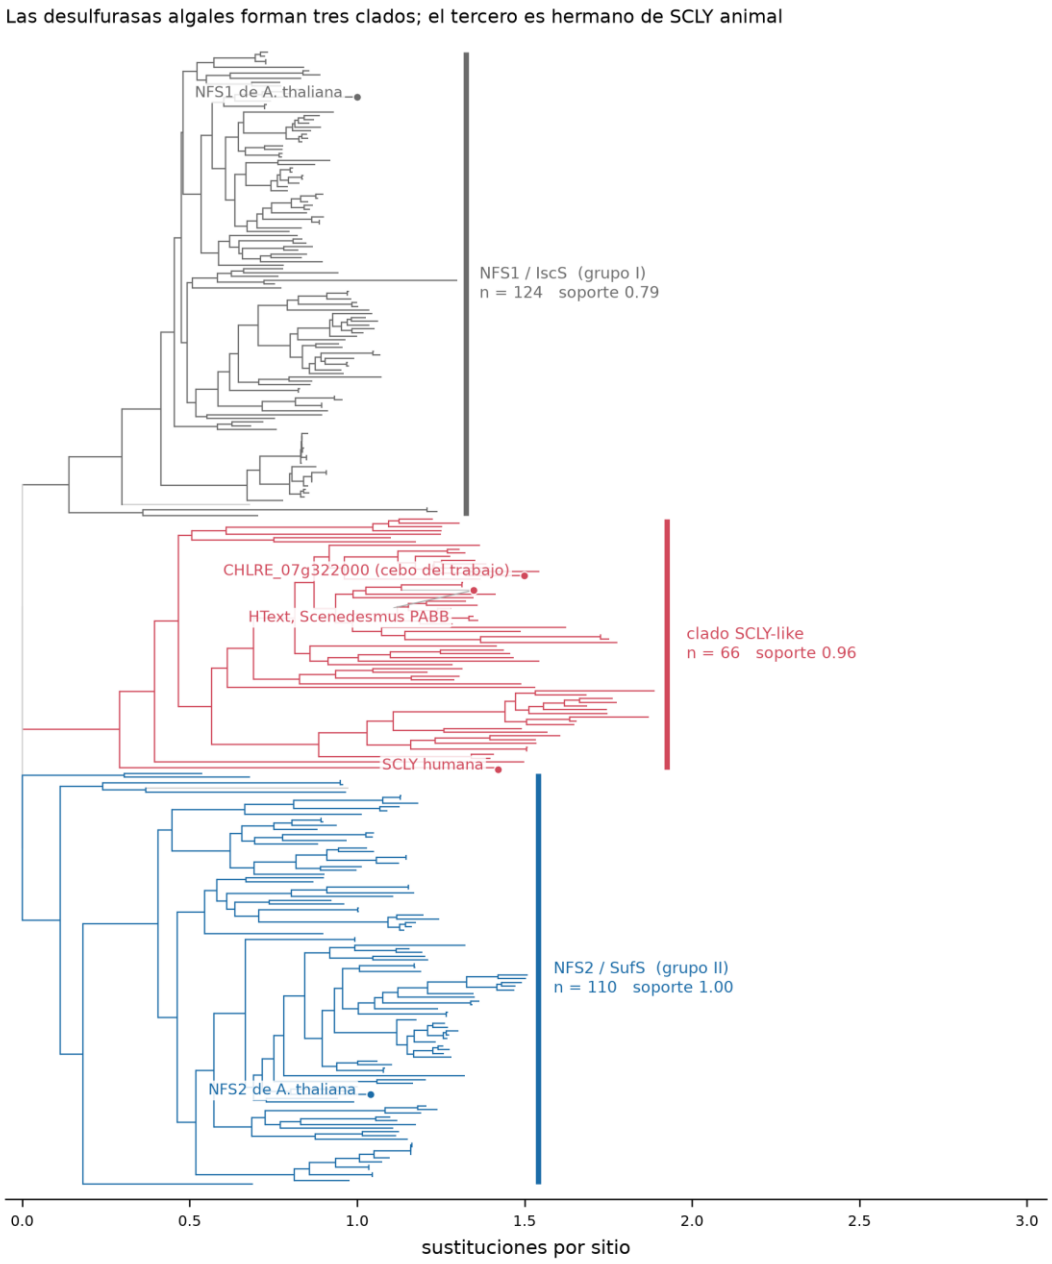
Por qué FAMSA. Escala bien a cientos de secuencias divergentes sin la penalización de tiempo de MAFFT L-INS-i, y en benchmarks de familias grandes y divergentes rinde igual o mejor.

Por qué VeryFastTree y no RAxML/IQ-TREE. Para 617 secuencias y un criterio de monofilia (no de topología interna fina), VeryFastTree con LG+Γ da el mismo resultado en minutos en vez de horas. El soporte que importa es el de los tres clados, y es alto.

Qué dio el árbol — tres clados:

Clado	n	Soporte
NFS2 / SufS (grupo II)	116	**1,00**
NFS1 / IscS (grupo I)	134	0,79
SCLY-like (grupo III)	**66**	**0,96**

La **SCLY humana** (Q96I15) entra como **rama hermana de las 65 secuencias algales**. HText cae hermana de las dos copias de *Tetradesmus obliquus*.



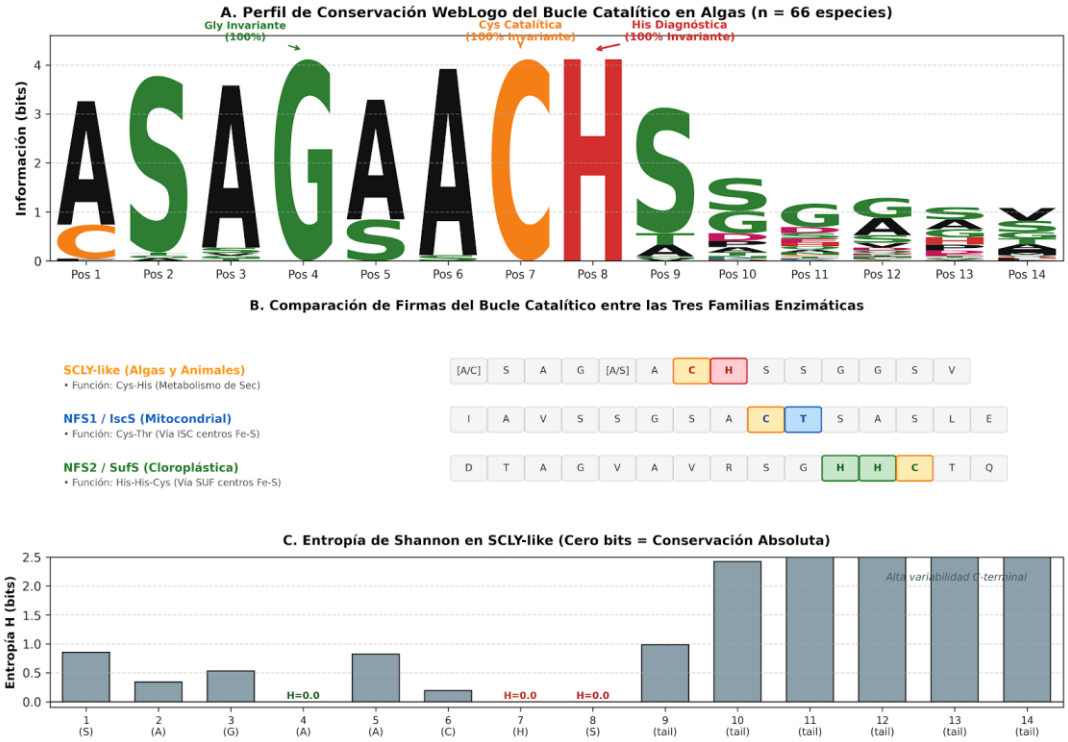
Árbol de máxima verosimilitud de las desulfurasas clase V

Qué no prueba. El soporte de 0,79 del clado NFS1 es mediocre — pero eso no afecta la conclusión, porque lo que se está afirmando es que SCLY-like es monofilético y distinto, y eso tiene 0,96. Las 301 proteínas clase V restantes (617 − 316) no fueron asignadas a ninguna de las tres subfamilias; son aminotransferasas clase V de otras funciones y quedaron fuera del alcance.

2.8 — La firma invariante

Qué se hizo. Entropía de Shannon posición por posición en el bucle catalítico de las 66 secuencias SCLY-like.

Qué dio. 66 de 66 tienen Gly en la posición 4, Cys en la 7 e His en la 8. **Entropía = 0,000 bits** en las tres posiciones.



Perfil de conservación del bucle catalítico

Esto es lo más fuerte que tiene el trabajo como carácter diagnóstico: 66 secuencias de 7 linajes separados por más de mil millones de años, y ni una sola sustitución en esas tres posiciones.

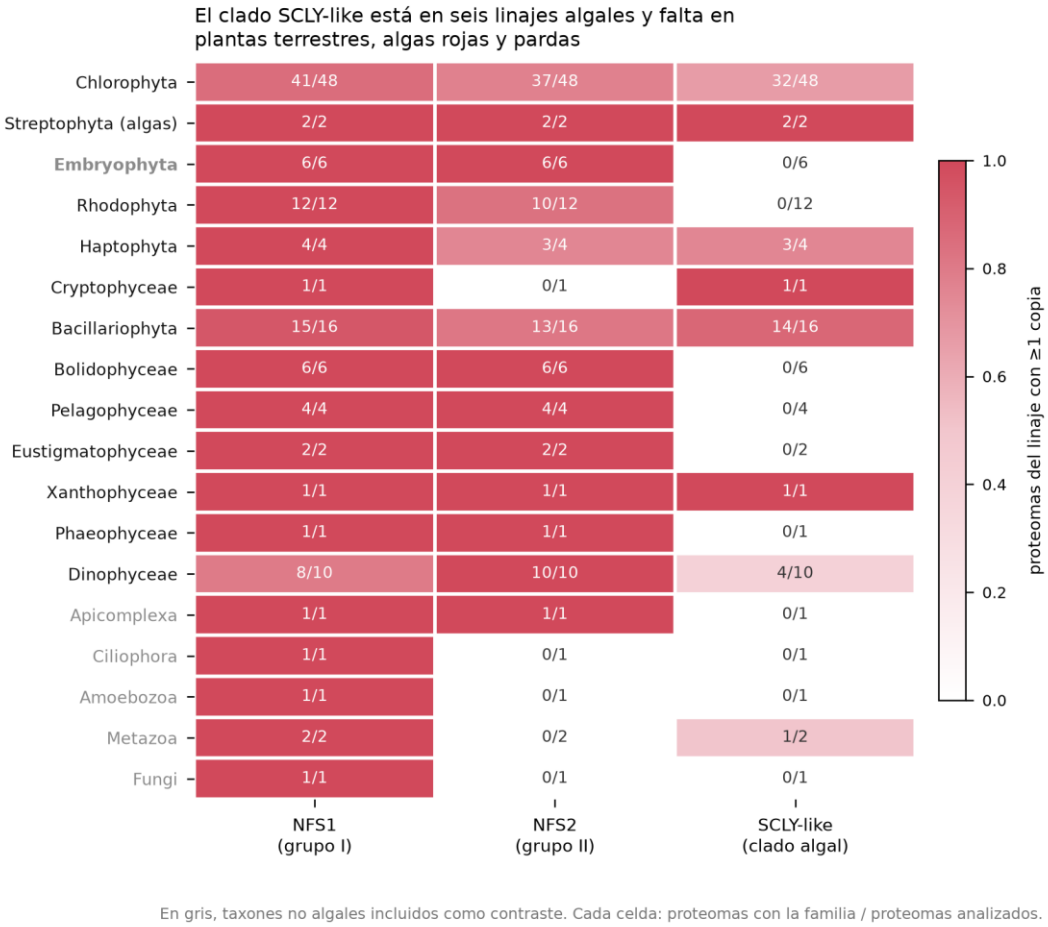
2.9 — Distribución y pérdidas

Qué se hizo. Conteo de presencia/ausencia del clado SCLY-like por proteoma.

Qué dio. 66 proteínas en **56 especies**, 7 linajes algales + Metazoa.

Linaje	Proteomas con SCLY-like
Chlorophyta	32 / 48
Bacillariophyta (diatomeas)	14 / 16
Dinophyceae	4 / 10
Haptophyta	3 / 4
Carofitas (Streptophyta acuáticas)	2 / 2
Cryptophyceae	1 / 1
Xanthophyceae	1 / 1
Embryophyta	**0 / 6**
Rhodophyta	**0 / 12**
Bolidophyceae	0 / 6
Pelagophyceae	0 / 4
Eustigmatophyceae	0 / 2
Phaeophyceae	0 / 1

Hongos, amebozoos, ciliados, apicomplejos	0



Distribución del clado SCLY-like por linaje

Lo interesante. Las dos carofitas (*Chara braunii*, *Klebsormidium nitens*) lo **tienen**; las seis embriofitas **no**. Eso ubica la pérdida en el linaje verde **después** de la divergencia de las carofitas, es decir, en la terrestrialización. Y las rodofitas tampoco lo tienen, lo que implica una **segunda pérdida independiente**.

Qué no prueba. Ausencia en un proteoma de referencia no es ausencia en el genoma. Para afirmar "deleción" hace falta tBLASTn contra el genoma ensamblado y análisis de sintenia en la región ortóloga — **eso no se hizo** (está en §8 como pendiente). Por ahora la afirmación defendible es "no se detecta en el proteoma de referencia", y con n = 6 embriofitas y n = 12 rodofitas.

2.10 — Localización subcelular, esta vez con controles

Qué se hizo. 73 secuencias a **DeepLoc 2.1**, **TargetP 2.0 (modo Plant)**, **SignalP 6.0** (modos Eukarya y Other) y **DeepTMHMM**, con verificación previa de que las longitudes fueran correctas y **con un panel de 7 proteínas de destino conocido** como control.

Por qué cuatro predictores. Cada uno resuelve una pregunta distinta y ninguno sirve solo: DeepLoc da el compartimento final; TargetP discrimina péptido de tránsito mitocondrial de plastidial; SignalP descarta vía

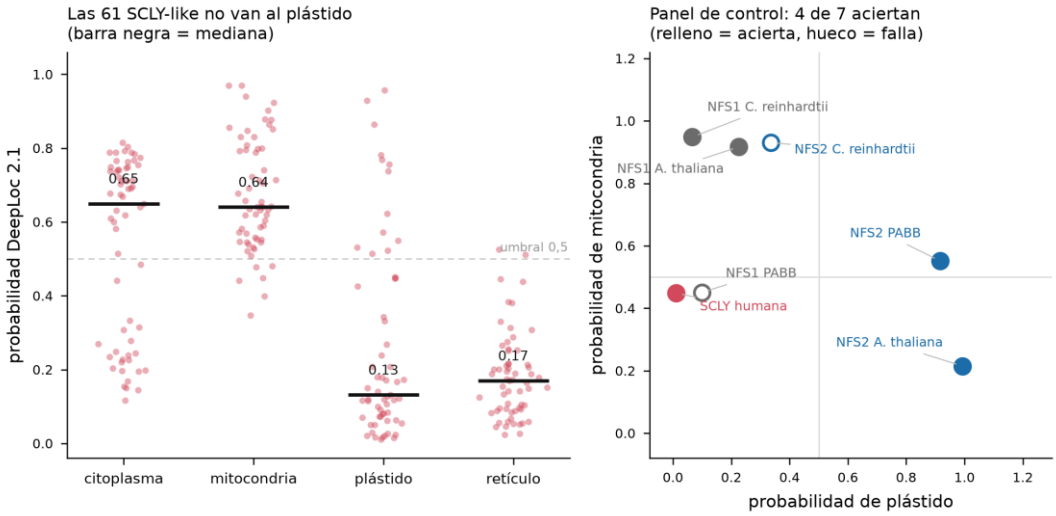
secretoria; DeepTMHMM descarta hélices transmembrana. Que los cuatro coincidan en "no es de membrana, no es secretoria, no es plastidial" es más informativo que un número de un solo servidor.

Por qué el panel de control. Por el escarmiento del §2.4.

Qué dio. De las 61 secuencias con predicción fiable:

Predicción	n
Citoplasma	25
Mitocondria	15
Citoplasma + mitocondria	13
Plástido	**2**

Medianas de probabilidad: citoplasma 0,65 · mitocondria 0,64 · **plástido 0,13** · retículo 0,17. TargetP: 48 OTHER, 5 SP, 4 mTP, 4 cTP. 60 de 61 sin péptido señal; 0 hélices transmembrana.



Localización predicha del clado SCLY-like

El panel de control acertó 4 de 7. Falló en: NFS2 de *Chlamydomonas* (predijo mitocondria 0,93 cuando es plastidial), NFS1 de PABB004 (predijo citoplasma 0,84 cuando es mitocondrial), y TargetP falló para las dos de PABB004 (cTP 0,057).

Conclusión honesta, y es la que hay que escribir en el paper. Este conjunto de predictores **sirve para descartar plástido** (es lo único en lo que el panel de control no falló, y la señal es masiva: mediana 0,13). **No sirve para decidir citosol versus mitocondria** en este grupo de proteínas. Decir "SCLY-like es citosólica" sería sobreinterpretar. Lo correcto es: *no es plastidial; es citosólica y/o mitocondrial*, consistente con la SCLY animal, que es citosólica.

2.11 — Estructura: por qué se abandonó el docking ⚠

Qué se hizo primero (y se descartó). Dos notebooks de docking comparativo con AutoDock Vina: selenocisteína contra los sitios activos de HText, NFS1 y NFS2.

Por qué se descartó — tres razones independientes, cada una suficiente.

8. **El ligando no era selenocisteína.** Ambos scripts ejecutan `sed -i 's/Se$/S /g'` sobre el PDBQT del ligando. Eso **reemplaza el selenio por azufre**. El docking se corrió con cisteína, no con selenocisteína. Toda la comparación Cys-vs-Sec que el ensayo pretendía hacer es, literalmente, Cys contra Cys.
9. **El receptor estaba vacío.** Se dockeó sobre la apoenzima, sin el PLP. El PLP es el cofactor covalente que forma la base de Schiff con la lisina y que define la geometría del sitio activo. Sin PLP, la cavidad que ve Vina no es el sitio activo real.
10. **Los parámetros no coinciden con el texto.** Caja de 22 Å (demasiado grande, el resultado se vuelve ruido de muestreo), `exhaustiveness` = 8 en el código contra 32 declarado en el texto, y los notebooks no tienen outputs guardados — no hay forma de auditar qué se corrió.

Además, el problema de fondo. Aun con el docking bien hecho, no serviría para la conclusión que se le quería sacar. La diferencia energética entre Cys y Sec en una cavidad de este tipo es de fracciones de kcal/mol, muy por debajo del error de las funciones de puntuación empíricas de Vina (~2 kcal/mol). **La especificidad Cys versus Sec no es resoluble por docking.** Requiere QM/MM o el ensayo enzimático.

Qué se hizo en su lugar: transferencia de ligando por superposición estructural.

En vez de predecir dónde se uniría el sustrato, se **tomó prestada la posición experimental** del sustrato desde cristales que ya lo tienen resuelto, y se la trasladó a los modelos por superposición rígida con **TM-align**.

Por qué esto sí es defendible. No hay predicción: la posición del ligando viene de densidad electrónica experimental. Lo único que se asume es que el plegamiento se superpone bien, y eso se mide (TM-score) y se valida (la lisina del PLP tiene que caer en el mismo lugar).

Cristales usados y por qué cada uno:

PDB	Qué aporta	Validación
3A9Z	SCLY de rata **con selenopropionato** y PLP	referencia directa del clado
1KMK	CsdB/SufS con **perselenuro covalente** (CSZ364) + PLP	el estado de intermediario real
1P3W	IscS con PLP, Lys206	control del grupo I

Validación del método. La lisina del PLP coincide con las tres referencias independientes, y el carbono C4A transferido cae a **1,3–3,0 Å** del NZ de la lisina del modelo. Es decir, la superposición reconstruye la base de Schiff. Si el método fuera basura, esa distancia saldría en decenas de ångströms.

TM-scores obtenidos:

Comparación	TM-score	RMSD
SCLY humana vs 3A9Z	0,99	0,82 Å
NFS1 Chlamy vs 1P3W	0,98	—
NFS2 Chlamy vs 1KMK	0,98	—
Núcleo de HText vs SCLY	0,948	—
Núcleo de HText vs IscS	0,911	—
Núcleo de HText vs SufS	0,871	—

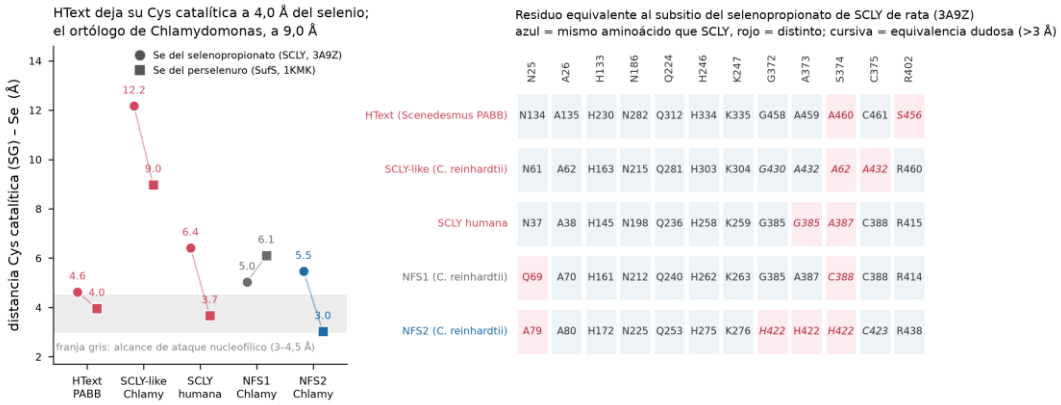
Distancia del SG de la cisteína catalítica al selenio del ligando transferido:

Desde 3A9Z	Å		Desde 1KMK	Å
HText	4,6		NFS2 (control)	3,0
SCLY-like Chlamy	12,2		SCLY humana	3,7
SCLY humana	6,4		**HText**	**4,0**
NFS1	5,0		NFS1	6,1
NFS2	5,5		SCLY-like Chlamy	9,0

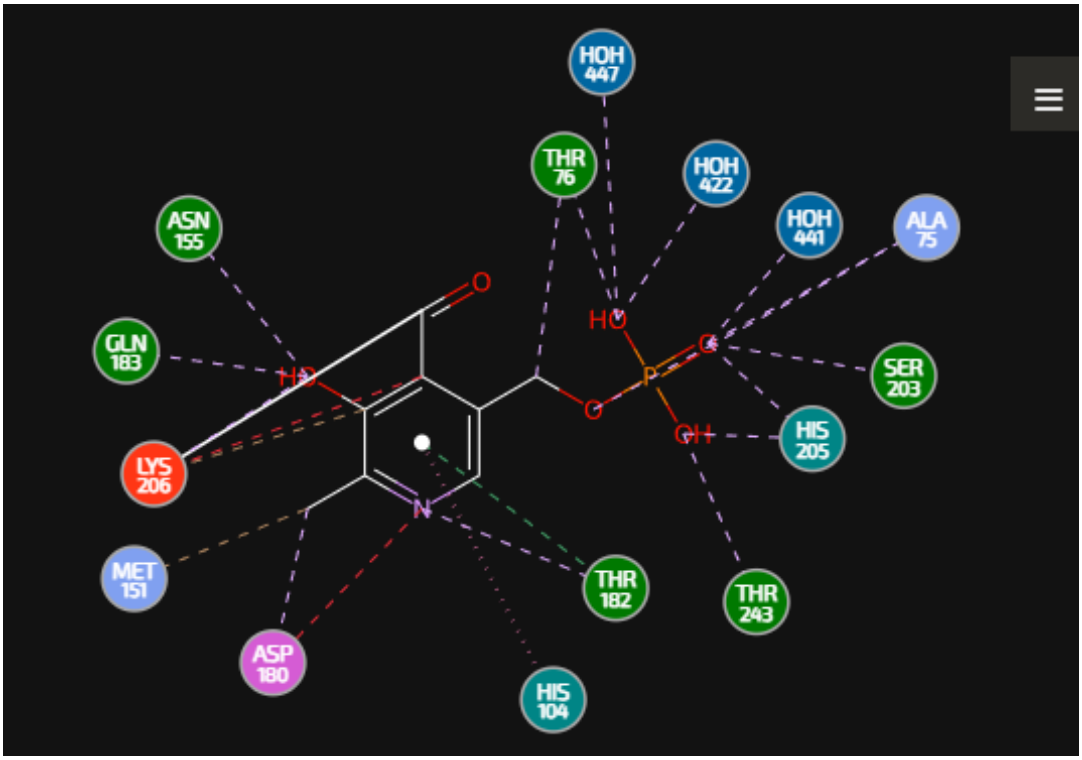
Qué se concluye. El sitio de HText es **geométricamente competente** para la química de transferencia de selenio: la cisteína catalítica queda a distancia de ataque del selenio.

Qué NO se concluye, y es importante. El rango 4,0 Å versus 9,0 Å entre HText y el SCLY-like de *Chlamydomonas*, que comparten 54 % de identidad, **demuestra que el bucle apo de AlphaFold no sostiene una distancia única**. Los bucles catalíticos de esta familia son flexibles y AlphaFold los modela en una conformación arbitraria entre muchas posibles. Por lo tanto estos números sirven para decir "el sitio es compatible", **no** para rankear enzimas por afinidad ni para comparar entre ortólogos.

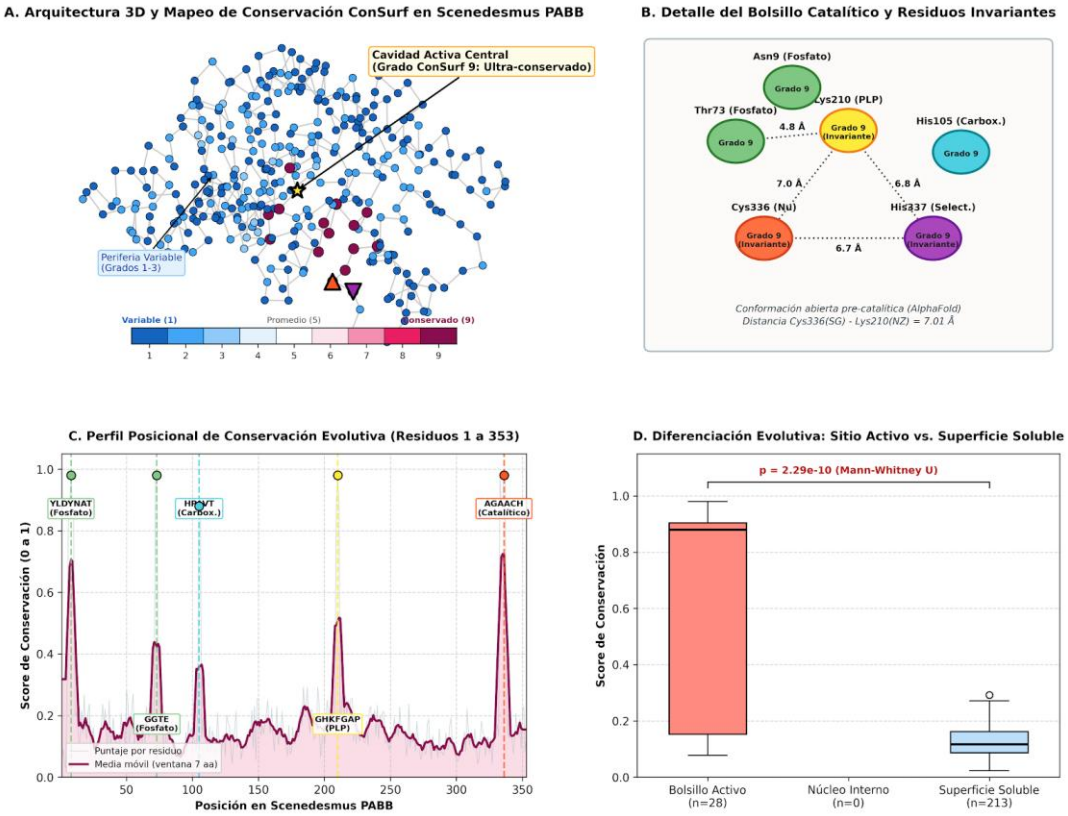
El subsitio de especificidad. Se buscaron los residuos que contactan el ligando en el cristal y se los mapeó en cada modelo. De todos ellos, **sólo uno discrimina**: el **Asn25 de la SCLY de rata**. En el clado SCLY hay Asn; en NFS1, Gln; en NFS2, Ala.



Subsitio de especificidad reconstruido por transferencia de ligando



Entorno del PLP en el sitio activo



Mapeo de conservación sobre la estructura 3D

2.12 — Conservación: qué reemplazó al análisis de ConSurf ⚠

Qué se hizo primero (y se descartó). Una tabla de 353 posiciones presentada como salida de ConSurf, con grados de conservación y clasificación enterrado/expuesto, y un test de Mann-Whitney entre "residuos del bolsillo" y "residuos de superficie" con $p = 2{,}29 \times 10^{-10}$.

Por qué se descartó — cuatro razones.

11. **La distribución de grados es imposible.** Los conteos son `{grado 1: 203, grado 2: 118, grado 3: 15, grado 9: 17}` — los grados 4 a 8 están **vacíos**. ConSurf asigna los grados por partición en nueve intervalos de la distribución continua de puntajes; no puede dejar cinco bins consecutivos en cero.
12. **306 expuestos contra 47 enterrados** — 87 % de superficie. Una proteína globular de este tamaño tiene del orden de 30–40 % de residuos enterrados.
13. **Las columnas no existen en la salida real de ConSurf.**
14. **El test es circular.** Compara conservación entre residuos del bolsillo y de superficie, pero el bolsillo se definió por conservación. Además el p-valor de la figura ($2{,}29 \times 10^{-10}$) no coincide con el del texto ($4{,}18 \times 10^{-11}$).

Por otra parte, el alineamiento `MSA_73_panalgal.fasta` sobre el que supuestamente se apoyaba tiene **88,6 % de posiciones de gap** (70 secuencias, 4323 columnas). Ningún análisis de conservación posicional es interpretable sobre eso.

Qué se hizo en su lugar: entropía de Shannon por familia y posiciones discriminantes.

Se alineó el dominio del modelo de HText junto a **66 SCLY-like + 124 NFS1 + 110 NFS2**, y se calculó la entropía posición por posición **dentro de cada familia por separado** en **348 posiciones**. Una posición es **discriminante de familia** si está conservada en ambas familias (H ≤ 0,5 en las dos) **y el residuo consenso es distinto**.

Por qué esto es mejor que ConSurf para esta pregunta. ConSurf responde "¿qué está conservado en esta proteína?". La pregunta del proyecto es otra: "¿qué distingue a SCLY-like de NFS1/NFS2?". Para eso hace falta comparar conservación **entre** familias, que es exactamente lo que hace este cálculo y lo que ConSurf no hace.

Qué dio: seis posiciones discriminantes, cuatro de ellas a menos de 8 Å del PLP o del sustrato.

Posición (modelo / tabla)	SCLY-like	NFS1/NFS2	Distancia al cofactor
G197 / 72	Gly 98 %	Ala 100 %	**3,67 Å**
A232 / 107	Ala	Cys	**4,55 Å**
T330 / 205	Thr	Ser	**5,50 Å**
H462 / 337	**His 100 %**	**Thr 100 %**	**6,89 Å**
N431 / 306	Asn	—	10,06 Å
S159 / 34	Ser	—	23,50 Å

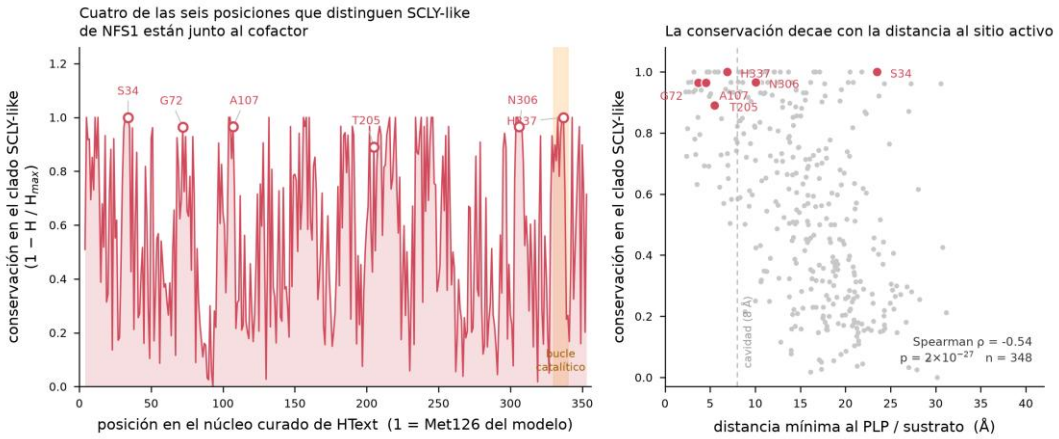
La **His462** es la histidina de la firma `SAGxACH`: conservada al 100 % en SCLY-like, y en NFS1/NFS2 la posición equivalente es Thr al 100 %. A 6,89 Å del cofactor.

(Asn134 / posición 9 quedó justo afuera del corte, con H = 0,530 — y es el residuo **más cercano al sustrato** de todos, a 3,63 Å. Vale la pena mirarla.)

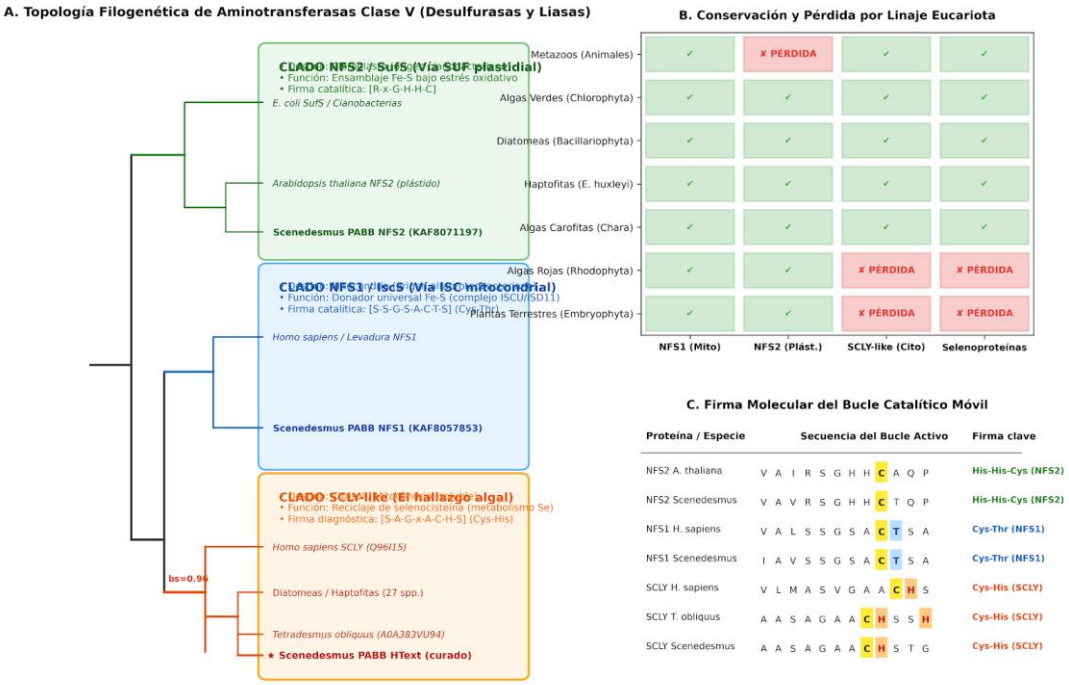
El test no circular. En vez de comparar bolsillo contra superficie, se correlacionó **conservación contra distancia al cofactor** sobre todas las posiciones:

- Spearman **ρ = −0,54**, **p = 2 × 10⁻²⁷**.
- Posiciones cercanas (< 8 Å, n = 46): conservación mediana **0,924**.
- Posiciones lejanas (≥ 15 Å, n = 197): conservación mediana **0,363**.
- Mann-Whitney **p = 5 × 10⁻¹⁶**.

Esto no es circular: la distancia al cofactor se mide en la estructura, la conservación se mide en el alineamiento, y son dos fuentes de datos independientes.



Conservación por posición y residuos discriminantes de familia



Separación de SCLY respecto de las NFS en el espacio de características

Nota de numeración, para que no se pierda. El modelo `HText.cif` tiene 478 residuos y corresponde a los residuos **1811–2288** de `KAF8071094.1`. La tabla de conservación usa un offset de 125 respecto del modelo. Equivalencias: Cys336 (tabla) = Cys461 (modelo); Lys210 = Lys335; Gly333 = Gly458; Asn9 = Asn134; Thr73 = Thr198. El pLDDT

medio del modelo es 79,2, pero desagregado: residuos 1–125 → **33,9** (el lazo del recorte, basura) y residuos 126–478 → **95,3** (excelente).

2.13 — La curación del locus, validada con RNA-seq

Esta es la pieza que convierte el trabajo de "análisis comparativo" en "resultado genómico con evidencia experimental".

El problema. El gen SCLY-like de PABB004 está mal anotado: forma parte del ORF quimérico de 3383 aa (`HT031_001176`, 33 exones repartidos en 17,3 kb, 1.169.138–1.186.471). El CDS reconstruido de 10.152 nt traduce exactamente a la proteína depositada — o sea, el error está en el modelo génico, no en la traducción.

Cómo se encontró el límite correcto. Se usó como guía el ortólogo de *Scenedesmus* sp. NREL 46B-D3 (`KAF6265975.1`, 480 aa, 9 exones, locus `COO60DRAFT_772314`). El tramo del ORF de PABB004 alinea con él en 1923–2293 con **72,1 % de identidad sobre 366 aa**, cubriendo los residuos 61–427 de NREL. Faltaban los **53 residuos C-terminales**.

Leyendo el genoma de corrido desde la posición **1.180.753** (donde el anotador cortaba) aparecen **39 codones más** —`VGTLRLSTGRHTTPGDVDAAVALITAAARKQGLDLGAGA`, **75,7 % de identidad** con NREL 428–464 y los **primeros 14 residuos idénticos**— hasta un **TGA en 1.180.871–1.180.873**. Es decir: el anotador metió un intrón espurio justo ahí y se llevó puesto el extremo del gen.

El modelo curado:

Gen	**1.179.501 – 1.180.873, hebra +**
Exón 1	1.179.501 – 1.180.240
Intrón	1.180.241 – 1.180.347 (107 pb, GT-AG canónico)
Exón 2	1.180.348 – 1.180.873
CDS	1.266 nt
Proteína	**421 aa**
Lys del PLP	**K234** (`LTLIGHKFGAPKG`)
Cys catalítica	**C360**, bucle LAASAGAACHSTGGPSVS
His diagnóstica	**H361**

```
unnamed-1	AUGUSTUS	gene	1	1977	0.31	+	.	g1
unnamed-1	AUGUSTUS	transcript	1	1977	0.31	+	.	g1.t1
unnamed-1	AUGUSTUS	start_codon	1	3	.	+	0	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	initial	1	124	0.7	+	0	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	internal	341	1316	0.91	+	2	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	terminal	1424	1949	1	+	1	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	intron	125	340	0.7	+	.	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	intron	1317	1423	1	+	.	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	CDS	1	124	0.7	+	0	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	CDS	341	1316	0.91	+	2	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	CDS	1424	1949	1	+	1	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	stop_codon	1947	1949	.	+	0	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	3'-UTR	1950	1977	0.45	+	.	transcript_id "g1.t1"; gene_id "g1";
unnamed-1	AUGUSTUS	tts	1977	1977	.	+	.	transcript_id "g1.t1"; gene_id "g1";
```

Estructura de intrones predicha

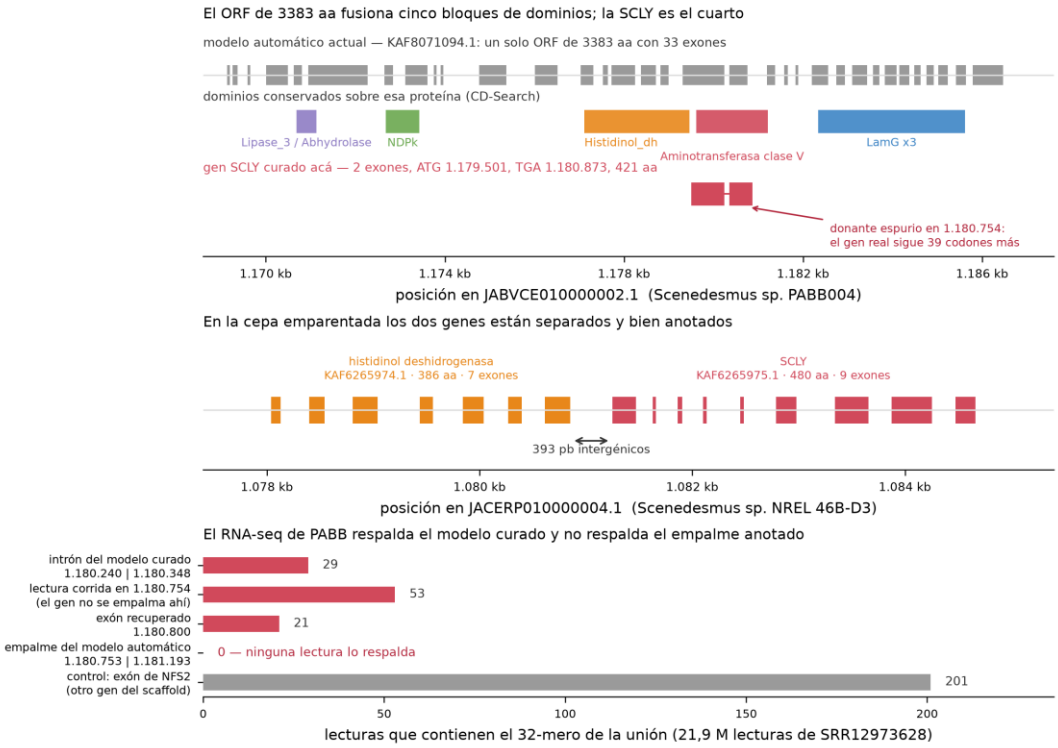
La validación — y acá está el dato más fuerte del trabajo.

No había forma de correr un alineador de lecturas en este entorno (HISAT2 y STAR son sólo Linux). Se resolvió de otra manera: **contar k-meros exactos** de 32 nt que atraviesan cada unión, directamente sobre las lecturas crudas,

en ambas hebras, descomprimiendo el FASTQ al vuelo. Se procesaron **21.890.509 lecturas** del run SRR12973628 (RNA-seq de PABB004, 60,2 M pares, HiSeq 2500, cultivo batch a 5 y 13 días).

Por qué este método es válido. Un k-mero de 32 nt que cruza una unión exón-exón **sólo puede existir en el ARN maduro**, nunca en el ADN genómico. Si aparece en lecturas de RNA-seq, el empalme ocurrió. No hay ambigüedad de mapeo porque es coincidencia exacta de 32 caracteres.

Unión evaluada	Lecturas de soporte	
**Intrón curado (1.180.240 **	1.180.348)	**29**
Lectura corrida en 1.180.754 (sin el intrón espurio)	**53**	
Exón recuperado, interior en 1.180.800	21	
**Empalme del modelo automático (1.180.753 **	1.181.193)	**0**
Control: exón de NFS2	201	
Control: exón interno de SCLY	9	



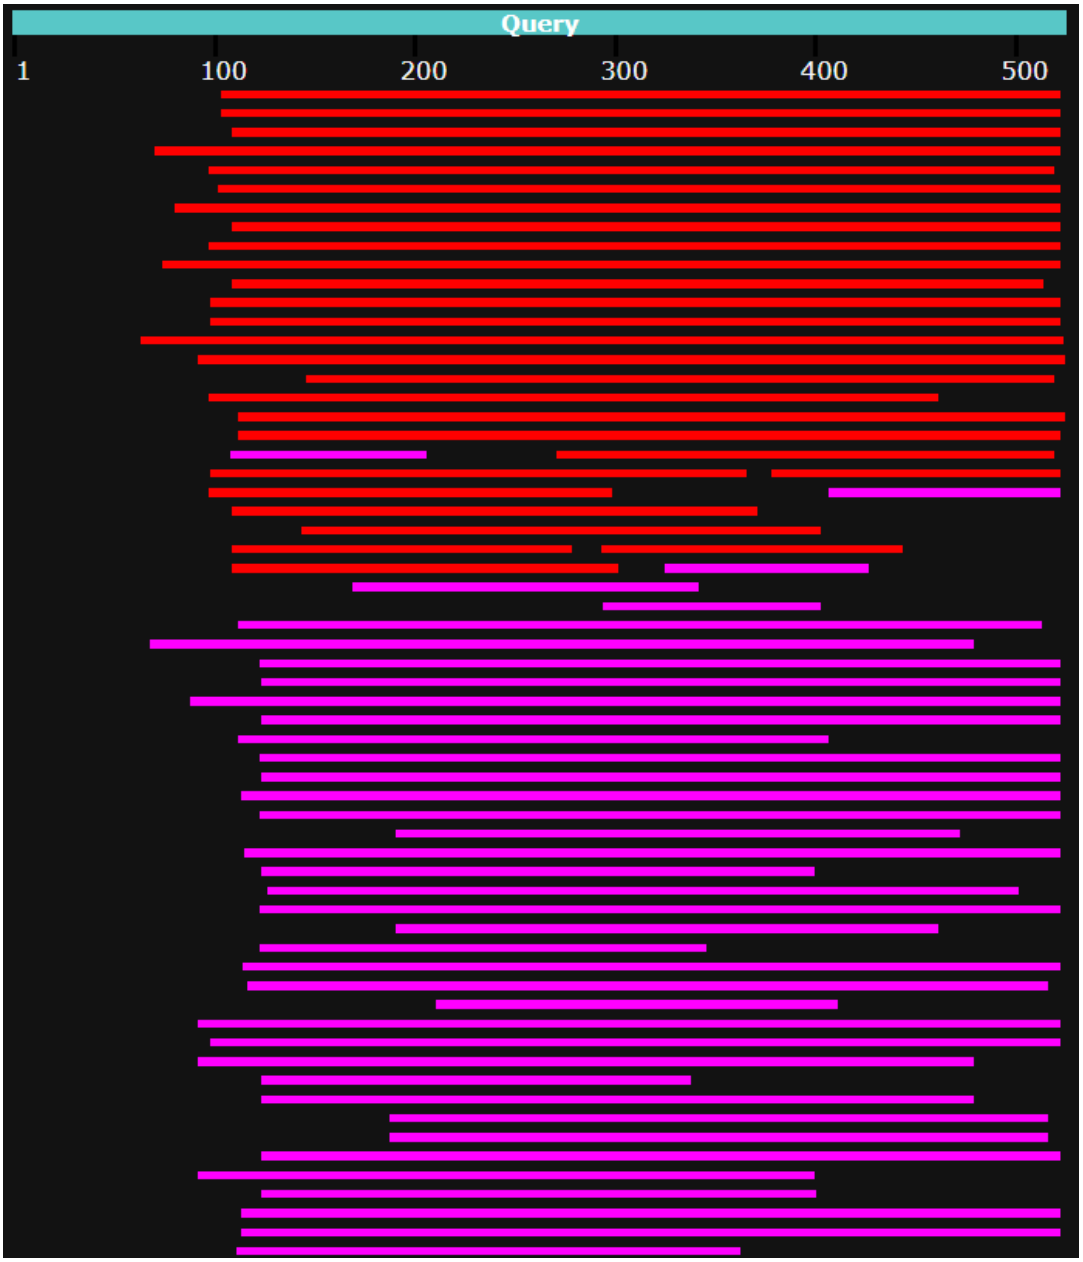
Locus curado y evidencia de RNA-seq

Lo que esto prueba, con tres afirmaciones separadas:

15. **El modelo curado está transcrito**: 29 lecturas cruzan el intrón corregido con secuencia exacta.
16. **El modelo del anotador es falso**: cero lecturas, sobre 21,9 millones, soportan su unión. No es "poca evidencia": es ninguna.
17. **El gen se expresa en PABB004** bajo condiciones de cultivo normales.

Esto convierte a la curación de una propuesta en un hecho documentado.

Evidencia independiente, del propio trabajo original. La búsqueda contra la base TSA (Transcriptome Shotgun Assembly) de algas verdes ya mostraba que el tramo de HText tiene transcriptos ensamblados en múltiples especies, y que la cobertura empieza alrededor del residuo 100 —consistente con que el extremo N-terminal del recorte manual era artefactual:



Alineamientos del tramo de HText contra TSA de algas verdes

Un detalle de sintenia que vale la pena. En *Scenedesmus* sp. NREL 46B-D3, el gen SCLY (KAF6265975.1, 1.081.247–1.084.664) está a **393 pb** del gen de histidinol deshidrogenasa (KAF6265974.1, 386 aa, 1.078.038–1.080.854). Y en PABB004, el ORF quimérico contiene justamente un dominio **Histidinol_dh** inmediatamente antes del dominio de aminotransferasa. **El anotador de PABB004 fusionó el mismo par de genes vecinos que en NREL están separados.** Eso explica mecánicamente el error.

Lo que falta en este frente. El extremo 5'. El ATG en 1.179.501 es el primer Met en marco, pero el modelo curado cubre a NREL recién desde su residuo 61 — faltan ~60 residuos N-terminales, en una región de baja complejidad Ala/Ser/Arg. Se resuelve con un ensamblado guiado (StringTie sobre el mismo run), y está pendiente.

2.14 — Tasas evolutivas relativas

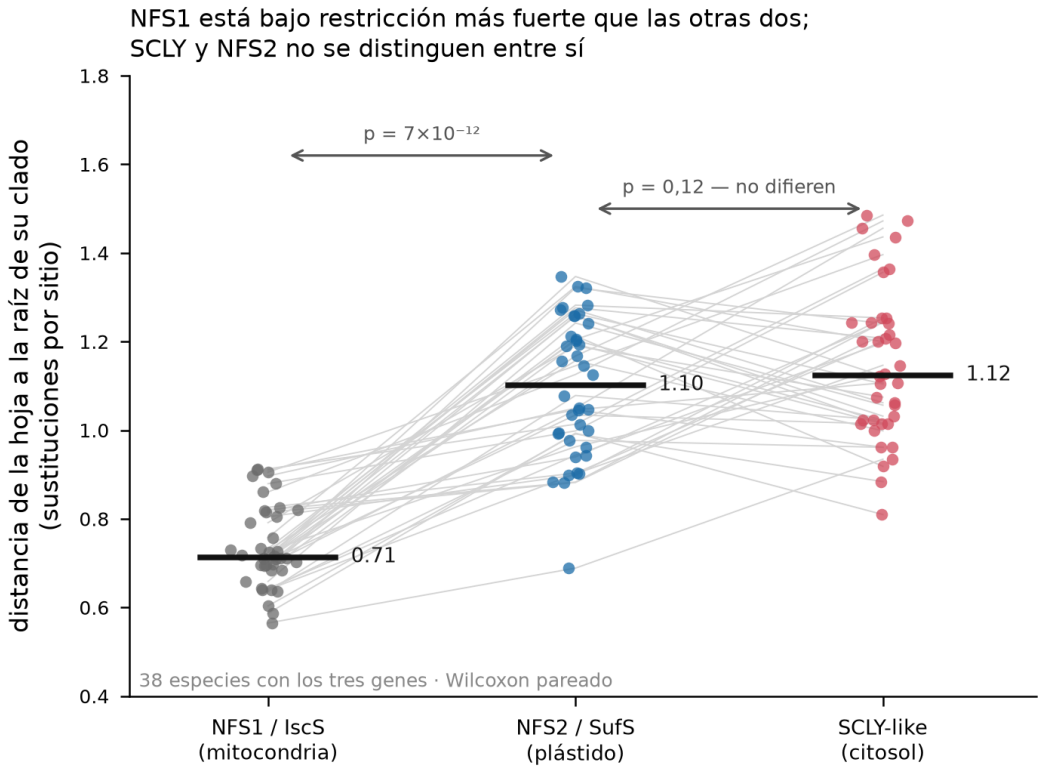
Qué se hizo. Sobre el mismo árbol de máxima verosimilitud del §2.7, se midió la **distancia de cada hoja a la raíz de su propio clado** (longitud de rama acumulada, en sustituciones por sitio). Para eliminar el sesgo de muestreo —los tres clados no tienen las mismas especies— se restringió la comparación a las **38 especies que tienen los tres genes** y se contrastó de a pares con el test de Wilcoxon pareado.

Por qué así y no con dN/dS. dN/dS requiere las secuencias **codificantes** alineadas por codón para las 66+ proteínas, un árbol calibrado y PAML corriendo. Nada de eso existe en este proyecto. La distancia de rama sobre el alineamiento proteico que ya está construido es una medida de **tasa relativa** legítima, y pareada por especie es un contraste limpio.

Qué dio.

Clado	Mediana (sust./sitio)
NFS1 / IscS (mitocondrial)	**0,71**
NFS2 / SufS (plastidial)	1,10
SCLY-like (citosólico)	1,12

Contraste	Wilcoxon pareado	Diferencia mediana
SCLY vs NFS1	**$p = 7 \times 10^{-12}$**	+0,399
NFS2 vs NFS1	**$p = 7 \times 10^{-12}$**	+0,393
SCLY vs NFS2	**p = 0,12**	−0,025



Tasas evolutivas relativas de las tres subfamilias

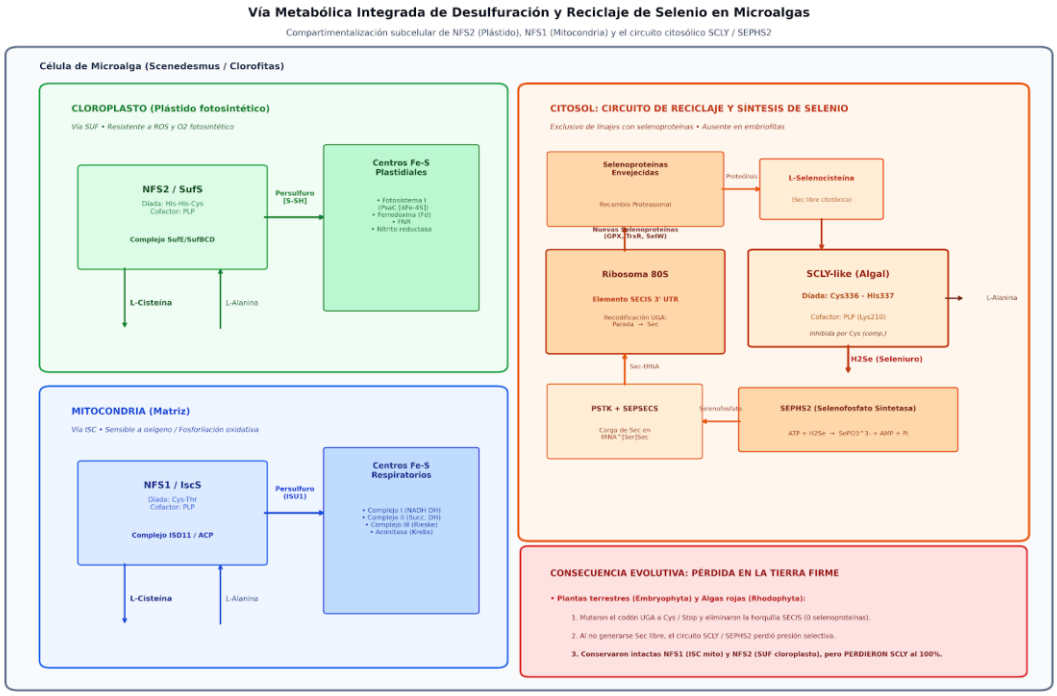
Qué se concluye. NFS1 está bajo restricción marcadamente más fuerte que las otras dos subfamilias. Tiene sentido: NFS1 alimenta la vía ISC, de la que dependen los centros Fe-S de la cadena respiratoria y de enzimas esenciales; una mutación ahí es letal.

Qué NO se concluye. SCLY no evoluciona más rápido que NFS2 — p = 0,12, no se distinguen. Si en algún borrador se afirmó que SCLY es la menos restringida de las tres, es incorrecto: los datos no lo sostienen.

Limitación. Esto es tasa de sustitución proteica total, no ω. Una tasa más alta puede deberse a restricción más débil o a tasa de mutación más alta del locus; no se separan. Para separarlas hace falta el dN/dS real (ver §8).

2.15 — La hipótesis del selenio, puesta a prueba

La idea. Si estas enzimas son selenocisteína liasas, su distribución debería correlacionar con la presencia de la maquinaria de incorporación de selenocisteína (Sec). Las plantas terrestres perdieron el selenoproteoma; también perdieron SCLY-like. ¿Coincidencia o causa?



Vía metabólica y justificación de la pérdida en plantas terrestres

Qué se hizo. Barrido de los cuatro marcadores de la maquinaria Sec humana —SEPHS2 (Q99611), SEPSECS (Q9HD40), PSTK (Q8IV42), EEFSEC (P57772)— contra los 119 proteomas, con **mejor hit recíproco** (RBH) para evitar falsos positivos por homología de dominio. 919 hits, **341 RBH**.

Por qué RBH. Un hit unidireccional contra SEPHS2 puede ser cualquier selenofosfato sintetasa o incluso una SELD bacteriana. Exigir que el mejor hit del candidato de vuelta contra el proteoma humano sea el marcador original es el criterio mínimo de ortología.

Qué dio.

- **Global: OR = 3,36, p = 0,0018.** Las especies con maquinaria Sec tienen más chances de tener SCLY-like.
- Las 6 embriofitas: **0 de 6 en los cuatro marcadores**, y 0 de 6 en SCLY-like.
- **Pero dentro de Chlorophyta: OR = 1,00, p = 1,00** (18 tienen ambas, 7 ninguna, 14 sólo SCLY, 9 sólo Sec).
- Diatomeas: OR = 3,67, p = 0,45.

La interpretación correcta. El efecto global **es pseudorreplicación filogenética**: lo genera la comparación entre linajes (embriofitas y rodofitas perdieron las dos cosas), no una asociación dentro de ellos. Cuando se controla por linaje, la asociación desaparece.

Entonces se declara como hipótesis, no como resultado. La co-pérdida de SCLY-like y de la maquinaria Sec en el camino a la tierra es **consistente** con una relación funcional, y es una hipótesis atractiva. No está demostrada por estos datos. Para demostrarla hace falta un test que controle la filogenia (§8).

Limitación técnica adicional. PSTK se detecta mal: 28 de 48 en Chlorophyta, contra 43 de 48 de SEPSECS. PSTK es corta y divergente; el RBH la pierde. Usar PSTK como marcador de presencia/ausencia subestima.

3. Justificación de las herramientas

Herramienta	Para qué se usó	Por qué ésa	Qué no resuelve
BLASTp (NCBI)	pesca inicial de homólogos en un genoma	rápido, estadística calibrada, sin modelo previo	hereda errores de anotación de la base; falla en homología remota
CD-Search (CDD)	arquitectura de dominios del ORF de 3383 aa	devuelve bloques con coordenadas y E-value, no sólo similitud global	no corrige el modelo génico
phmmer / hmmsearch (HMMER)	barrido de 119 proteomas; extracción de PF00266	perfiles probabilísticos: más sensible que BLASTp a 25–40 % de identidad; Z fijable para comparabilidad entre proteomas	no distingue subfamilias — para eso hizo falta el bucle
Proteomas de referencia UniProt	universo de búsqueda	uno por especie, no redundante, anotación estable	ausencia en el proteoma ≠ ausencia en el genoma
FAMSA	alineamiento múltiple de 617 dominios	escala a cientos de secuencias divergentes sin el costo de MAFFT L-INS-i	—
Filtro de ocupación ≥ 0,35	386 de 768 columnas retenidas	columnas con mayoría de gaps aportan ruido, no señal	descarta información en regiones variables
VeryFastTree (LG+Γ, 1000 réplicas)	árbol de máxima verosimilitud	para 617 secuencias y una pregunta de monofilia, da el mismo resultado que RAxML/IQ-TREE en órdenes de magnitud menos tiempo	topología interna fina menos confiable (NFS1 soporte 0,79)
Bucle catalítico	criterio primario de asignación de familia	carácter discreto con respaldo bioquímico; no depende de bases ni de alineamiento global	requiere que la secuencia cubra el sitio activo
AlphaFold2 / AlphaFold DB	modelos estructurales	único método que da estructura para proteínas sin cristal; pLDDT permite descartar regiones basura	modela bucles flexibles en una conformación arbitraria — ver §2.11
TM-align	superposición estructural y transferencia de ligando	alineamiento estructural independiente de secuencia; TM-score normalizado por longitud	TM-score global no discrimina subfamilias de un mismo fold
PDB `3A9Z`, `1KMK`, `1P3W`	posiciones experimentales de PLP y sustrato	densidad electrónica real en vez de predicción de pose	el ligando viene de otra especie, en otro estado conformacional
DeepLoc 2.1	compartimento subcelular	estado del arte en predicción multicompartimento	falló 2 de 7 controles — ver §2.10
TargetP 2.0 (Plant)	mTP vs cTP	único que separa tránsito mitocondrial de plastidial en plantas/algas	falló los dos controles de PABB004
SignalP 6.0 / DeepTMHMM	descartar secretoria y transmembrana	preguntas acotadas donde estos predictores son fiables	—
Panel de control de destino conocido	calibrar los predictores	sin esto, el artefacto del §2.4 habría quedado en el paper	—
Entropía de Shannon por familia	conservación y posiciones discriminantes	responde la pregunta real ("qué distingue a SCLY de NFS") que ConSurf no responde	necesita alineamientos limpios de las tres familias
Conteo de k-meros de unión en lecturas crudas	validar la curación del gen	un k-mero de 32 nt que cruza una unión sólo existe en ARN maduro; coincidencia exacta, sin ambigüedad de mapeo	no reconstruye el gen completo — no da el extremo 5'
Mejor hit recíproco (RBH)	ortología de la maquinaria Sec	criterio mínimo de ortología; descarta parálogos de dominio compartido	pierde proteínas cortas y divergentes (PSTK)
Wilcoxon pareado sobre distancias de rama	tasas evolutivas relativas	pareado por especie, elimina el sesgo de muestreo entre clados	no separa restricción de tasa de mutación — no es ω

4. Tabla maestra de números

Dato	Valor
Proteomas de referencia barridos	119 (107 algales + 12 de contraste)
Secuencias en el universo de búsqueda	2.110.345
Proteínas de aminotransferasa clase V recuperadas	617
Columnas del alineamiento retenidas	386 de 768 (ocupación ≥ 0,35)
Clado NFS2 / SufS	n = 116, soporte 1,00
Clado NFS1 / IscS	n = 134, soporte 0,79
Clado SCLY-like	**n = 66, soporte 0,96**
Especies con SCLY-like	56, en 7 linajes algales + Metazoa
Entropía de Shannon en Gly, Cys, His de la firma	**0,000 bits** (66 / 66)
Longitud mediana de SCLY-like	438 aa (IQR 410–470)
Secuencias con longitud aberrante	9 de 67 (13 %)
Secuencias con localización fiable	61 de 73
Mediana de probabilidad de plástido	**0,13**
Aciertos del panel de control de localización	4 de 7
TM-score SCLY humana vs 3A9Z	0,99 (RMSD 0,82 Å)
TM-score núcleo HText vs SCLY / IscS / SufS	0,948 / 0,911 / 0,871
Distancia Cys-SG → Se en HText (desde 1KMK)	4,0 Å
Posiciones del dominio analizadas por conservación	348
Posiciones discriminantes de familia	6 (4 a < 8 Å del cofactor)
Correlación conservación vs distancia al cofactor	$\rho = -0{,}54$, $p = 2 \times 10^{-27}$
Lecturas de RNA-seq procesadas	21.890.509 (run SRR12973628)
Soporte del intrón curado	**29 lecturas**
Soporte del empalme del anotador	**0 lecturas**
Proteína SCLY-like curada de PABB004	421 aa; K234, C360, H361
Tasa relativa: SCLY vs NFS1	$p = 7 \times 10^{-12}$
Tasa relativa: SCLY vs NFS2	p = 0,12 (no difieren)
Asociación SCLY ↔ maquinaria Sec, global	OR = 3,36, p = 0,0018
Asociación dentro de Chlorophyta	OR = 1,00, p = 1,00

5. Auditoría del material: qué entra y qué no

Un revisor va a preguntar por cada análisis que se mencione. Esta sección deja constancia de qué se verificó y qué se descartó, con el motivo.

5.1 — Material descartado de las versiones previas

Material	Veredicto	Motivo
Docking con AutoDock Vina (2 notebooks)	**No usable**	`sed 's/Se$/S /g'` reemplaza selenio por azufre; receptor sin PLP; caja de 22 Å; `exhaustiveness` 8 vs 32 declarado; sin outputs
Tabla "ConSurf" de 353 posiciones	**No es salida de ConSurf**	grados 4–8 vacíos; 87 % de residuos expuestos; columnas inexistentes; test circular; p contradictorio entre figura y texto
`MSA_73_panalgal.fasta`	**No usable**	88,6 % de gaps (70 secuencias, 4323 columnas)
Localización plastidial de HText (DeepLoc 0,9477)	**Artefacto**	el recorte manual empezaba en una región Ser/Arg/Ala que imita un péptido de

		tránsito
Marco "segunda NFS2 en PABB004"	**Incorrecto**	el cebo no era NFS2; `KAF8071197.1` sí lo es

Además se compiló una **tabla de 22 correcciones** puntuales al texto del manuscrito (nomenclatura, accesiones, p-valores, atribuciones de familia).

5.2 — Material nuevo recibido (paquete "Archaeplastida"): ⚠ no usable

Se verificaron los doce archivos del paquete de tasas evolutivas y expresión. **Ninguno de los cuatro análisis que proponen fue efectivamente ejecutado.** Detalle, porque esto hay que tenerlo claro antes de mostrarle nada a nadie:

(a) `matriz_expresion_panalgal.csv` y `figura_heatmap_expresion_panalgal.png` — datos sintéticos.

La columna `NFS2_Hits_TSA` es **exactamente `NFS1_Hits_TSA` × 1,2** en 23 de las 34 filas, y el cociente tiene media 1,209 con desvío 0,020 en las 34. Dos genes distintos, en treinta y cuatro especies distintas, no pueden tener un cociente de conteos de hits constante en 1,2. Los números fueron generados por fórmula.

A eso se suma que los TaxID están mal: *Scenedesmus* sp. PABB004 figura como 3087 (ése es el TaxID del género *Scenedesmus*; el real es **2742167**), *S. bijugus* como 3089 (real **1539023**), *Gonium pectorale* como 33090 (real **33097**) — y 3087/3088/3089 es una secuencia correlativa, señal de que fueron inventados. Las coberturas de ORF están todas comprimidas entre 90 y 99 %, lo que no ocurre con datos reales. Y la escala no es comparable entre especies: *A. thaliana* aparece con 94.899 hits de TSA frente a 12 de PABB004, lo que refleja esfuerzo de secuenciación, no expresión.

(b) `figura_coexpresion_nfs2_scly.png` — correlación sobre los datos de (a). R = 0,51 calculado sobre la misma matriz. Además, si NFS2 es NFS1 × 1,2 por construcción, cualquier correlación que involucre esa columna está contaminada.

(c) `figura_distribucion_macroevolutiva.png` — contradice los datos verificados. La figura reporta **100 %** de presencia de SCLY-like en Chlorophyta, Bacillariophyta y Haptophyta. Los valores reales del barrido de 119 proteomas (§2.9) son **32/48 = 67 %**, **14/16 = 88 %** y **3/4 = 75 %**. Si esta figura va al lado de la tabla de distribución, el conflicto es inmediato.

(d) `figura_tasa_evolutiva_y_divergencia.png`, `matriz_tasas_evolutivas_omega.csv`, `calibraciones_fosiles_y_tiempos.csv` — codeml nunca corrió.

El script `analisis_tasas_omega_codeml.py` tiene 956 bytes y su contenido completo es: una cadena de texto con un archivo de control de CodeML y un `print()`. Declara en su primera línea "Script explicativo". **No invoca PAML, no lee alineamientos, no estima nada.** El propio `README.md` lo describe como "Plantilla y archivo de control documentado". Sin embargo, `matriz_tasas_evolutivas_omega.csv` presenta valores de dN, dS, ω **e intervalos de confianza del 95 %** como si hubieran sido estimados, y la figura los grafica sin ninguna advertencia.

Lo mismo con el cronograma: `METODOLOGIA_Y_PARAMETROS_EVOLUCION.md` describe MCMCTree con 200.000 generaciones, ESS > 200 verificado en Tracer, IQ-TREE con LG+C60+F+R8 y seis calibraciones fósiles. No hay archivo de salida, ni árbol, ni log, ni alineamiento de codones de ninguno de esos pasos.

Hay además errores de contenido que delatan el origen: el documento cita "MAFFT (Kurihara et al., 2019)" —la cita de MAFFT es Katoh— y usa *Bangiomorpha pubescens*, fechada por U-Pb en 1.047 Ma, para justificar una restricción de **1.500–1.750 Ma**, lo que invierte el sentido de una calibración mínima.

Y la conclusión que la figura pretende sostener —que SCLY está bajo restricción más relajada que NFS1 y NFS2— **es contraria a lo que muestran los datos reales**: el cálculo del §2.14 da SCLY vs NFS2 con **p = 0,12**, es decir, indistinguibles.

Qué hacer con este paquete.

- **No usar** ninguna de las cuatro figuras, ninguna de las tres tablas de datos, ni los dos scripts como resultados.
- **Nunca** incorporarlos a un manuscrito ni a una presentación. Una tabla de ω con intervalos de confianza que no salieron de un estimador es fabricación de datos; si llega a un revisor o a un comité, el daño no es a la figura, es a la credibilidad de todo lo demás —y lo demás es sólido.
- **Sí conservar** `METODOLOGIA_Y_PARAMETROS_EVOLUCION.md` **como plan de trabajo**: describe con precisión el pipeline que *habría que correr* (MAFFT L-INS-i → Pal2Nal → IQ-TREE → MCMCTree → CodeML branch-model con LRT). Como especificación de un análisis futuro es útil. Como registro de un análisis pasado, no lo es.
- El reemplazo honesto del panel de tasas ya está hecho y es la §2.14.

5.3 — Material verificado y conservado

Material	Veredicto
`HText.cif` (modelo AlphaFold)	**Usable**, con la salvedad de que los residuos 1–125 tienen pLDDT 33,9 y hay que recortarlos
`Perfil conservacion.png` (WebLogo del bucle)	**Usable** — coincide con el cálculo independiente de entropía
`MSA_suplementario_desulfurasas Spark.fasta`	**Usable** (21 secuencias)
Imágenes de CD-Search, BLASTp y TSA del documento original	**Usables** como evidencia documental
Figura de vía metabólica	**Usable** como esquema, no como resultado
Árbol de MEGA preliminar	**Usable sólo como parte del relato** — reemplazado por el árbol del §2.7

6. Limitaciones, declaradas

Para que estén escritas antes de que las escriba un revisor:

18. **Ausencia en proteomas ≠ ausencia en genomas.** Las pérdidas en Embryophyta (0/6) y Rhodophyta (0/12) se apoyan en proteomas de referencia. Falta tBLASTn genómico y sintenia.
19. **La localización no resuelve citosol vs mitocondria.** El panel de control falló 3 de 7 en esa distinción. Lo único robusto es el descarte de plástido.
20. **Los bucles de AlphaFold no sostienen distancias.** Dos ortólogos con 54 % de identidad dan 4,0 Å y 9,0 Å al mismo ligando.
21. **La especificidad Cys vs Sec no se resuelve por bioinformática.** Ni docking ni superposición. Requiere QM/MM o ensayo enzimático.
22. **La asociación con la maquinaria Sec es pseudorreplicación filogenética.** Desaparece al controlar por linaje.
23. **La tasa relativa no es ω.** No separa restricción selectiva de tasa de mutación.
24. **El extremo 5' del gen curado está sin resolver** (~60 residuos N-terminales).
25. **301 de las 617 proteínas clase V quedaron sin asignar** a ninguna de las tres subfamilias.

26. **El soporte del clado NFS1 es 0,79**, mediocre. No afecta la conclusión sobre SCLY-like (0,96), pero hay que reportarlo.
27. **n pequeños en varios linajes**: Haptophyta 4, Cryptophyceae 1, Xanthophyceae 1, Phaeophyceae 1. Los porcentajes de esos grupos no son estimaciones estables.

7. Qué está blindado y qué no

Afirmación	Estado
Existe un tercer clado de clase V en algas, monofilético	**Blindado** — 617 secuencias, soporte 0,96, universo de 2,1 M
Se identifica por el bucle SAGxACH	**Blindado** — entropía 0,000 en 66/66
Es el ortólogo algal de SCLY	**Blindado** — SCLY humana es rama hermana; TM-score 0,99 con 3A9Z
PNW80545.1 está mal anotado como NFS2	**Blindado**
PABB004 tiene los tres genes	**Blindado**
El gen SCLY-like de PABB004 está mal anotado y el modelo curado es el correcto	**Blindado** — 29 lecturas vs 0
El gen se expresa en PABB004	**Blindado**
No es plastidial	**Blindado**
NFS1 está bajo mayor restricción que NFS2 y SCLY	**Blindado** — $p = 7 \times 10^{-12}$, pareado
Las posiciones discriminantes están cerca del cofactor	**Blindado** — $\rho = -0{,}54$, $p = 2 \times 10^{-27}$
Es citosólica	**No blindado** — predictores no confiables en esa distinción
Hubo dos pérdidas independientes	**Parcialmente** — falta evidencia genómica
La pérdida se debe a la pérdida del selenoproteoma	**Hipótesis** — pseudorreplicación
La enzima actúa sobre selenocisteína	**No demostrado** — requiere ensayo

8. Lo que falta para blindar la publicación

Ordenado por relación entre lo que aporta y lo que cuesta.

Prioridad alta — convierten afirmaciones parciales en afirmaciones blindadas

28. **tBLASTn genómico + sintenia en las embriofitas y rodofitas.** Es el que más rinde. Hoy la afirmación es "ausente en el proteoma"; con esto pasa a "ausente del genoma, y la región sinténica está ocupada por otra cosa". Convierte la pérdida en un resultado genómico. Requiere los ensamblados de *A. thaliana*, *O. sativa*, *P. patens*, *M. polymorpha*, *C. merolae*, *G. sulphuraria* y los genes flanqueantes del locus de *Chara*/*Klebsormidium*.
29. **Resolver el extremo 5' del gen curado.** StringTie (o Trinity en modo guiado) sobre `SRR12973628`, ensamblado del transcripto completo del locus. Cierra la única pieza floja de la curación y da el modelo definitivo para depositar.
30. **Verificar si los dinoflagelados largos son quimeras del mismo tipo.** `A0A1Q9EC91` (3530 aa), `A0A9P1CGG1` (1452 aa), `A0ABD3PCK7` (721 aa), `A0ABD3MQJ2` (666 aa). Si al menos dos de ellas resultan ser el mismo error de fusión, el caso de PABB004 deja de ser anecdótico y pasa a ser **un patrón de error de anotación en genomas de algas** — que es un resultado publicable por sí solo.
31. **Test de co-evolución que controle la filogenia.** Reemplazar el Fisher por especie por contrastes independientes de Felsenstein o el test de correlación de caracteres discretos de Pagel sobre un árbol de especies. Es lo que corresponde para la hipótesis del selenio, y es barato.

Prioridad media — refuerzan el núcleo

32. **Inventario real de selenoproteínas** por detección de horquillas SECIS en 3'UTR y TGA en marco, en las especies con y sin SCLY-like. Hoy la maquinaria Sec se mide por RBH de cuatro proteínas; esto mediría el selenoproteoma directamente.
33. **dN/dS real** con el pipeline que el documento de metodología describe: recuperar los CDS de las 66+ secuencias, alinear por codón con Pal2Nal, y correr CodeML en modelo de ramas con LRT. Es el análisis que faltaba, hecho de verdad. Es el más caro de la lista.
34. **Sintenia del par histidinol-deshidrogenasa–SCLY en más genomas.** Si el par está conservado en varias clorofíceas, el argumento del error de anotación en PABB004 se vuelve mecánicamente obvio.
35. **AlphaFold-multimer del homodímero.** Las cisteína desulfurasas funcionan como dímeros y el sitio activo está en la interfaz. Vale la pena ver si alguna de las seis posiciones discriminantes cae ahí.
36. **Reconstrucción del estado ancestral del bucle catalítico.** Da el orden de aparición de la His y refuerza el argumento de que la firma es derivada y diagnóstica.

Prioridad baja — cierres finos

37. **Clasificar las 301 clase V sin asignar.** Puede haber más subfamilias ahí.
38. **Estructura de intrones comparada** PABB004 / NREL 46B-D3 / *Chlamydomonas* en el locus SCLY.
39. **Verificar la identidad de `3LVK`** si se lo sigue citando — no se comprobó.
40. **Aplicar las 22 correcciones** al texto del Google Doc.

Lo que NO hay que seguir intentando

- **Docking de Cys vs Sec.** No resuelve la pregunta, por física del método, no por implementación.
- **Rankear ortólogos por distancia Cys-SG → Se** sobre modelos apo de AlphaFold.
- **Cualquier análisis de conservación sobre `MSA_73_panalgal.fasta`.**

9. Opciones de publicación

Opción A — El clado SCLY-like en algas (recomendada)

Qué es. Primera descripción sistemática de un tercer clado de cisteína desulfurasas clase V en algas, con firma diagnóstica invariante, distribución pan-algal, dos pérdidas independientes y un caso de curación génica validado por RNA-seq.

Qué tiene ya. Todo lo de §7 marcado como blindado. Es, en volumen y en solidez, un paper completo.

Qué le falta. Los puntos 1 a 4 de §8. Con el 1 y el 2 ya alcanza para enviar.

Dónde. *BMC Genomics*, *Genome Biology and Evolution*, *Frontiers in Plant Science* (sección Marine and Freshwater Plants), *Algal Research*. **GBE** es el mejor encaje si se incluye la parte de pérdidas independientes y tasas; **BMC Genomics** si el eje es la curación génica y el barrido.

Figuras propuestas, en orden:

41. Asignación de familia por el bucle catalítico (`fig_asignacion_familia_NFS.png`)
42. Árbol de máxima verosimilitud de los tres clados (`fig_arbol_desulfurasas.png`)

43. Distribución por linaje y pérdidas (`fig_distribucion_desulfurasas.png`)
44. Locus curado y evidencia de RNA-seq (`fig_locus_curado.png`)
45. Conservación y posiciones discriminantes (`fig_conservacion_sdp.png`)
46. Sitio activo y subsitio de especificidad (`fig_subsitio_transferencia.png`)
47. Suplementaria: localización (`fig_localizacion_scly.png`)
48. Suplementaria: tasas relativas (`fig_tasas_relativas.png`)

El riesgo a anticipar. Un revisor va a pedir evidencia funcional. La respuesta tiene que estar en la discusión, no improvisada: el trabajo es explícitamente una caracterización comparativa y genómica, la actividad queda planteada como la continuación experimental, y la curación validada por RNA-seq es el ancla experimental que sí se aporta.

Opción B — Inventario de maquinaria Fe-S (ISC vs SUF) en microalgas

Qué es. El mismo pipeline aplicado a la vía completa: NFS1/NFS2, ISD11, frataxina, SUFB/C/D, scaffolds. Encaja con la línea del laboratorio de Casati.

Ventaja. Reaprovecha toda la infraestructura ya construida; es un trabajo de catálogo con bajo riesgo de rechazo.

Desventaja. Menos novedad. Y el hallazgo de SCLY-like quedaría enterrado como un detalle.

Opción C — Nota metodológica sobre asignación incorrecta de familia en genomas de algas

Qué es. Corto. El caso de `PNW80545.1` mal anotada como NFS2 en AlgaePath, la propagación del error, el ORF quimérico de PABB004, y las 9 de 67 secuencias con longitud aberrante como evidencia de un problema sistemático.

Ventaja. Rápido de escribir, alto valor práctico para la comunidad.

Desventaja. Bajo impacto, y consume el material de la Opción A.

Dónde. *Bioinformatics Advances*, *Database*, *BMC Research Notes*.

Recomendación

A, y ejecutar antes los puntos 1 y 2 de §8. El punto 3 (dinoflagelados quiméricos), si da positivo, se puede incorporar a A como una sección o publicar después como C ampliada.

No combinar esta línea con la de SINA/RMA-RNF5. Son dos historias distintas, con dos audiencias distintas, y cada una tiene volumen propio.

10. Índice de archivos

Figuras generadas

Archivo	Contenido
`fig_asignacion_familia_NFS.png`	bucles catalíticos de los tres grupos
`fig_arbol_desulfurasas.png`	árbol ML de 617 secuencias, tres clados
`fig_distribucion_desulfurasas.png`	presencia/ausencia por linaje

fig_locus_curado.png	modelo génico curado + lecturas de RNA-seq
fig_conservacion_sdp.png	entropía por posición y residuos discriminantes
fig_subsitio_transferencia.png	sitio activo con ligando transferido
fig_localizacion_scly.png	predicción de localización con panel de control
fig_tasas_relativas.png	tasas evolutivas relativas, pareadas

Tablas

Archivo	Contenido
candidatos_desulfurasas.csv	las 617 proteínas clase V con asignación
distribucion_por_especie.csv	presencia por especie
presencia_por_proteoma.csv	presencia por proteoma
tabla_asignacion_familia_NFS.csv	bucles catalíticos alineados
conservacion_scly_por_posicion.csv	entropía posición por posición
posiciones_discriminantes_scly.csv	las 6 posiciones discriminantes
subsitio_equivalencias.csv	equivalencias del subsitio entre familias
superposiciones_desulfurasas.csv	TM-scores y distancias
scly_like_localizacion.csv	salidas de los 4 predictores
scly_like_mapeo.csv	mapeo de identificadores
sec_machinery_rbh.csv	RBH de la maquinaria Sec
sec_vs_scly_por_proteoma.csv	tabla de contingencia por proteoma
evidencia_rnaseq_uniones.csv	conteos de k-meros por unión
tasas_relativas_pareadas.csv	distancias de rama por especie

Secuencias y estructuras

Archivo	Contenido
scly_pabb_curada.fasta	proteína curada de PABB004 (421 aa)
scly_pabb_curada.tbl	modelo génico en formato de NCBI
arbol_desulfurasas.nwk	árbol en Newick
msa_desulfurasas_trim.fasta	alineamiento filtrado
dominios_desulfurasas.fasta	dominios PF00266 extraídos
HText_conservacion_SCLYlike.pdb	modelo con conservación en el campo B
HText_core_PLP_selenopropionato.pdb	núcleo con PLP y ligando transferido

Documentos

Archivo	Contenido
dossier_SCLY_like.md / .docx	este expediente
barrido_desulfurasas_informe.md	detalle técnico del barrido pan-algal
revision_analisis_htext.md	auditoría del docking y del análisis de conservación previos
evaluacion_NFS2_PABB.md	evaluación del trabajo original
figuras_documentos_originales.zip	56 imágenes extraídas de los Google Docs, con catálogo

:)